¿Funcionó el piloto en Tumbes y Piura? ¿Se puede expandir al norte y al Perú?

Validación externa y viabilidad de expansión · PEU Ciencia de Datos (INEI)

Christopher · Maykol · Marcia · Luz Ángela

4 de noviembre de 2026

Tablero: `marciashapiama.github.io/iapn-inei` Detalle: `docs/06_VALIDACION_Y_VIABILIDAD_EXPANSION.md`

Qué responde esta presentación

Parte 1 · Validación

1. ¿Las cifras son internamente coherentes?
2. ¿Coinciden con una fuente oficial independiente (INDECI)?
3. ¿Qué no funciona todavía?
4. ¿Son adecuados los datos que usamos?

Parte 2 · Expansión

5. ¿Cuánto crece el problema al ir al norte o a todo el Perú?
6. ¿Qué es viable con la infraestructura gratuita actual?
7. ¿Qué cambios de código y de datos hacen falta?
8. Propuesta para decidir con el docente

1. Validación interna: las cifras son coherentes

Prueba	Resultado
La suma de los distritos coincide con el total; dentro $\leq$ 500 m $\leq$ 1 km	Se cumple: 38 pruebas automáticas, también en GitHub Actions
La población está en su lugar: correlación con la densidad de edificaciones (fuente independiente)	$r = 0{,}80$ (antes de corregir: 0,00)
Población WorldPop por distrito frente a la estimación 2020	Razón de 0,85 a 1,10 en los distritos de más de 40 mil habitantes
Radar reciente recalculado con la referencia seca corregida	Control de calidad aprobado; estado *vigente*
Tablero publicado, mapa 2D y descargas	11/11 pruebas contra el sitio real

Excepción conocida: Piura tiene razón 1,75 porque absorbe a Veintiséis de Octubre (unos 130 mil habitantes), un distrito que no existe en los límites GADM.

2. Validación externa: ¿qué comparamos?

Fuente independiente

Tablas oficiales de **INDECI (SINPAD-COEN), 2003–2024**: afectados por distrito y tipo de peligro. No las usamos para calcular nada, así que sirven para validar.

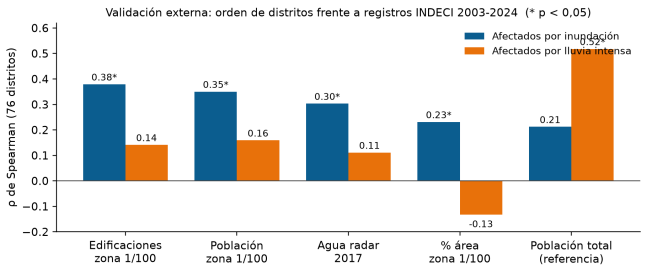
Método

- Los 76 distritos se emparejan por departamento, provincia y distrito (76/76).
- **Correlación de rangos de Spearman** (ρ): ¿el orden de los distritos coincide?
- Se analizan por separado **inundación** y **lluvia intensa**.

Por qué se valida el orden y no la cantidad

- INDECI suma 22 años de eventos; la exposición es la de un escenario actual.
- INDECI cuenta personas *afectadas*; nosotros, personas *expuestas*.
- Los registros dependen de lo que reporta cada municipalidad.

2. Resultado: funciona para inundación, no para lluvia intensa



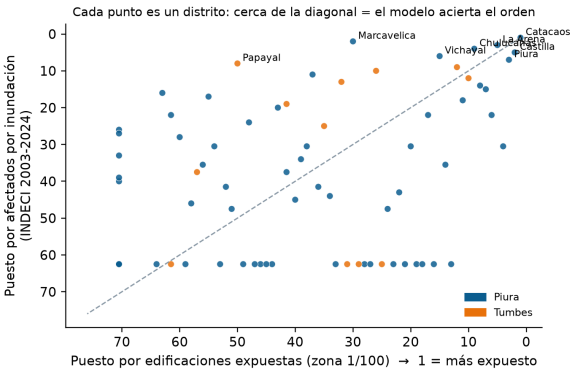
Inundación por desborde

Edificaciones expuestas: $\rho = 0{,}38$ ($p < 0{,}001$). Población expuesta: $\rho = 0{,}35$. Ambas superan a la población total (0,21): la exposición aporta información propia.

Lluvia intensa

La explica la población total ($\rho = 0{,}52$), no la zona inundable fluvial.

2. Distrito por distrito: ¿acierta el orden?



La franja horizontal de abajo son distritos sin afectados por inundación registrados (empatados en el último puesto).

Top 15 de INDECI (afectados por inundación y lluvia) frente al top 15 del modelo (población expuesta):

coinciden 9 de 15: Castilla, Catacaos, Chulucanas, Colán, La Arena, La Unión, Piura, Tambo Grande y Tumbes.

No los capta el modelo: Pacaipampa, Yamango, Montero y Las Lomas. Están en la sierra, donde dominan la lluvia intensa y los huaicos.

3. Lo que todavía no funciona bien

Radar en ciudades

En Catacaos, 2017, solo detectó 1,1 km², aunque fue de los distritos más inundados. El radar con umbral fijo es un **mínimo**: no ve el agua entre edificios.

Alerta semanal (ML)

No supera con certeza a la climatología: el IC de la diferencia incluye el 0. Captura el 46 % de las emergencias de Tumbes y solo el 5 % de las de Piura. **No usarla como alerta.**

Índice de riesgo

$\rho = 0{,}34$ con los afectados por inundación, similar a la exposición sola. Sobrevalora distritos pequeños casi cubiertos por la mancha y sin afectados registrados (Rinconada Llicuar, Bellavista de la Unión).

Conclusión del piloto

El resultado más sólido es la **exposición a inundación fluvial por distrito**: está validada en su orden contra una fuente oficial independiente. El radar, el índice compuesto y la alerta semanal necesitan mejoras antes de usarse para decidir.

4. ¿Es adecuada la base de datos?

Componente	¿Adecuado?	Qué falta
Peligro fluvial (JRC 1/10, 1/100)	Sí, como base	Estudios CENEPRED/SIGRID; **lluvia intensa y huaicos**; defensas ribereñas
Población (WorldPop 2026)	Sí (corregida)	Censo 2017 y proyecciones oficiales del INEI por distrito o manzana
Edificaciones (Open Buildings)	Sí	Uso residencial y material de la vivienda (censo)
Salud (RENIPRESS)	Sí	Verificar coordenadas en campo
Colegios (OpenStreetMap)	No es la ideal	Padrón ESCALE (MINEDU) con código modular y matrícula
Límites (GADM)	No es la ideal	Límites oficiales INEI/IGN (faltan 2 distritos; la licencia no permite redistribuir)
Vulnerabilidad (pobreza, IDH)	Parcial	Edad, discapacidad, vivienda y saneamiento (Censo 2017)
Daños para entrenar (DesInventar)	Parcial	Serie fechada SINPAD 2016–2026
Lluvia y caudal (modelados)	Parcial	Estaciones SENAMHI y ANA; avisos oficiales

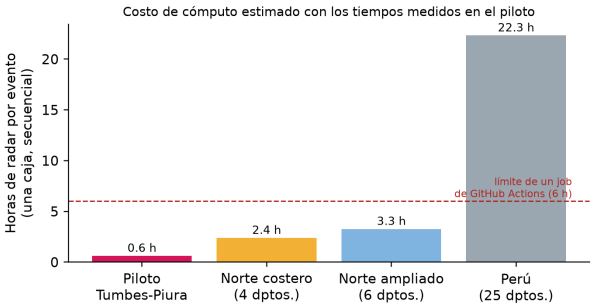
5. ¿Cuánto crece el problema?

Escenario	Dist.	Población	Área
Piloto: Tumbes, Piura	78	2,3 M	1×
Norte costero: + Lambayeque, La Libertad	199	5,8 M	3,6×
Norte ampliado: + Cajamarca, Áncash	492	8,6 M	4,9×
Perú: 25 departamentos	1 893	34,4 M	33,5×

Área = caja envolvente que hay que descargar y procesar, comparada con el piloto. Población: estimación 2020 por distrito.



6. Costo de cómputo (con los tiempos medidos en el piloto)



Límites gratuitos de GitHub

6 h por job · ∼16 GB de RAM por runner · sitio de Pages de 1 GB · archivos de hasta 100 MB

- **Norte:** cabe en el plan gratuito si se procesa un departamento por job.
- **Perú:** 22 h por evento en una sola caja no caben; hay que **dividir** por departamento o cuenca y correr el radar solo cuando hay un evento.
- Open Buildings nacional (∼180 MB) supera el límite de 100 MB por archivo: hay que partirlo por departamento.

7. Veredicto de viabilidad

Norte costero

Viable a corto plazo (1–2 semanas).

Mismo método y mismas fuentes; la caja y los departamentos pasan a ser parámetros. Es donde El Niño costero golpea más (1983, 1998, 2017, 2023).

Norte ampliado

Viable con ajustes.

Cajamarca y Áncash son sobre todo sierra: dominan la lluvia intensa y los huaicos, que el JRC no cubre. Hace falta una capa de peligro adicional (CENEPRED/SIGRID, INGEMMET).

Perú completo

Posible, pero con otra arquitectura.

Datos y descargas por departamento, mapas en teselas, radar por evento y por cuenca, y otra lógica para la inundación estacional de la Amazonía.

Cambio de código necesario	**Esfuerzo**
Caja y departamentos como configuración (no constantes)	1–2 días
Salidas por departamento y selector en el mapa	2–3 días
Workflow con *matrix* por departamento y pruebas parametrizadas	2 días

8. Propuesta para decidir con el docente

Ruta recomendada

1. **Consolidar el piloto**: límites del INEI, padrón ESCALE, población oficial.
2. **Agregar el peligro por lluvia intensa y huaicos**, la carencia que mostró la validación.
3. **Ampliar a la costa norte** (4 departamentos) y repetir la validación con INDECI.
4. Fase posterior: **cobertura nacional** con la arquitectura por departamento.

Preguntas al docente

- ¿Priorizamos profundizar la validación en Tumbes y Piura o ampliar ya a la costa norte?
- ¿Es posible obtener del INEI los límites oficiales y la población por distrito o manzana?
- ¿Basta la validación de orden con INDECI o se espera una validación con datos de campo?

Gracias

Tablero: `marciashapiama.github.io/iapn-inei`

Mapa 2D: `marciashapiama.github.io/iapn-inei/mapa2d.html`

Reproducir: `python herramientas/validacion_indeci.py`
`python herramientas/viabilidad_expansion.py`