PROGRAMA DE EXTENSIÓN UNIVERSITARIA: CIENCIA DEL DATO (PEU-CD)
INSTITUTO NACIONAL DE ESTADÍSTICA E INFORMÁTICA (INEI)

PROPUESTA FINAL DE PROYECTO INTEGRADOR

Indicador Adelantado de la Producción Nacional (IAPN)

Nowcasting sectorial con aprendizaje automático y temperatura del mar

Integrantes:

Calle Rentería, Christopher Paul
Mendizábal Huanca, Luz Ángela
Ramírez Santos, Maykol Ángel
Shapiama De La Cruz, Marcia

Lima, Perú
Octubre de 2026

1. Motivación y justificación

El Instituto Nacional de Estadística e Informática (INEI) difunde el Informe Técnico de Producción Nacional alrededor del día 15 del segundo mes posterior al mes de referencia. Por ejemplo, las cifras de julio de 2026 se publicaron el 15 de setiembre. Este rezago, de aproximadamente 45 días, responde al tiempo necesario para recopilar y validar la información de los sectores productivos. Sin embargo, durante ese periodo los usuarios no disponen de ninguna cifra de producción del mes que ya concluyó. Varias oficinas de estadística atienden esta necesidad con estimaciones tempranas, conocidas como estimaciones *flash*, que ganan oportunidad a cambio de una menor exactitud; por ello, su error debe medirse y comunicarse junto con la cifra (Eurostat, 2017).

La necesidad es mayor en 2026. De acuerdo con el comunicado oficial N.° 16-2026 de la Comisión Multisectorial encargada del Estudio Nacional del Fenómeno El Niño (ENFEN), El Niño Costero iniciado en marzo tendría con mayor probabilidad una magnitud extraordinaria entre setiembre de 2026 y enero de 2027 (ENFEN, 2026). En estos episodios la producción de la pesca, el agro y la manufactura primaria cambia de manera brusca, y los métodos que se basan en la evolución reciente de cada serie pierden precisión. Los eventos de 2017 y 2023 permiten estudiar este problema con datos observados.

Objetivo general. Construir y evaluar un indicador adelantado de la producción nacional y de sus nueve sectores, basado en modelos de aprendizaje automático, que el INEI pueda calcular antes de la publicación oficial y cuya exactitud se conozca, también durante episodios de El Niño.

Tabla 1. Objetivos específicos y preguntas de investigación

Objetivo específico	Pregunta de investigación
OE1. Estimar la variación interanual de la producción nacional y de sus nueve sectores antes de la publicación oficial mediante modelos de aprendizaje automático.	**P1.** ¿Estiman los modelos de aprendizaje automático con menor error que tres referencias simples: repetir la última cifra publicada, usar la variación de la electricidad y un modelo autorregresivo?
OE2. Evaluar si la temperatura del mar mejora la estimación durante El Niño, en los episodios de 2017 y 2023 y en el evento en curso de 2026.	**P2.** ¿Cuánto disminuye el error al incorporar la temperatura del mar en los meses de El Niño de 2017 y 2023? ¿Las estimaciones de agosto y setiembre de 2026, registradas antes de su publicación, contienen la cifra oficial dentro de su intervalo?
OE3. Construir un índice diario de actividad a partir de la generación eléctrica y medir su aporte a la estimación del mes en curso.	**P3.** ¿A partir de qué día del mes el índice permite estimar la producción con menor error que las referencias?

Necesidad del INEI y área interesada. El área usuaria es la Dirección Técnica de Indicadores Económicos (DTIE), responsable del Informe Técnico de Producción Nacional. El indicador le serviría de dos maneras. En primer lugar, como referencia interna del mes que se está midiendo, acompañada de un intervalo que expresa su incertidumbre. En segundo lugar, como control de calidad: si la cifra sectorial en preparación se aleja del intervalo estimado, la serie puede revisarse antes de su publicación. La propuesta complementa la estadística oficial y no plantea difundir cifras no certificadas.

Contribución esperada. El proyecto aportaría un indicador sectorial cuyo error se mide por sector y por día del mes, del cual no hemos identificado antecedentes públicos en el Perú; evidencia sobre el valor de la temperatura del mar para medir la producción durante El Niño; y un índice diario de actividad basado en la electricidad. Si los modelos de aprendizaje automático no superan a las referencias simples, ese resultado también es útil para el INEI, porque indicaría que no se justifica adoptar métodos más complejos.

2. Revisión inicial de literatura y marco teórico

El *nowcasting* consiste en estimar el valor presente o del pasado inmediato de una variable que se publica con rezago, utilizando información que se conoce antes que ella (Giannone et al., 2008). Los bancos centrales lo emplean de forma regular para anticipar el producto bruto interno (PBI), y su práctica se ha extendido al uso de grandes volúmenes de datos (Bok et al., 2018). En el Perú, el Banco Central de Reserva (BCRP) ha publicado dos estudios recientes sobre el PBI agregado: Tenorio y Perez (2024) combinan indicadores económicos con variables extraídas de textos, y Flores et al. (2024) comparan doce métodos de aprendizaje automático con más de 170 predictores. Ninguno de ellos estima la producción por sectores ni evalúa su desempeño durante El Niño, que es el espacio en el que se ubica este proyecto.

Desde la perspectiva de la estadística oficial, el Código de Buenas Prácticas de las Estadísticas Europeas considera la exactitud y la oportunidad como dimensiones distintas de la calidad (Eurostat, 2017). Una estimación temprana mejora la oportunidad, por lo que su exactitud debe medirse y comunicarse junto con la cifra estimada.

El aprendizaje automático agrupa métodos que aprenden relaciones a partir de los datos sin imponer de antemano una forma funcional. Su aplicación a series macroeconómicas mensuales se ve limitada por el tamaño de la muestra, pues desde 1995 se dispone de alrededor de 380 observaciones por serie. Montero-Manso y Hyndman (2021) muestran que esta limitación se atenúa con un modelo global, es decir, un único modelo entrenado con varias series relacionadas a la vez; las competencias internacionales de pronóstico M4 y M5 confirman este resultado (Makridakis et al., 2020, 2022). Dentro de este enfoque se emplearán dos métodos. LightGBM estima una suma de árboles de decisión en la que cada árbol corrige los errores de los

anteriores (Ke et al., 2017), y fue la base de los métodos con mejor desempeño en la competencia M5. El Temporal Fusion Transformer (TFT) es una red neuronal diseñada para series de tiempo que combina capas recurrentes de tipo LSTM (Hochreiter & Schmidhuber, 1997) con un mecanismo de atención; además de la estimación, produce intervalos e indica qué variables influyeron más en cada resultado (Lim et al., 2021). Esta propiedad es relevante para una institución estadística, que debe poder explicar sus cifras (Chakraborty & Joseph, 2017).

En cuanto a los datos de alta frecuencia, Lewis, Mertens y Stock (2022) construyen un índice semanal de actividad económica para Estados Unidos. En este proyecto se aplica una idea similar con la generación eléctrica diaria, que en el Perú está estrechamente vinculada a la minería y la manufactura. Por último, Cashin, Mohaddes y Raissi (2017) encuentran que El Niño tiene efectos macroeconómicos significativos y diferentes según el país, lo que justifica incorporar información climática en la medición de la actividad de corto plazo.

3. Estrategia empírica

3.1 Fuentes de datos y acceso

La variable objetivo es la variación porcentual interanual de la producción nacional y de sus nueve sectores, tal como la publica el INEI en el Informe Técnico de Producción Nacional. Esta cifra se tomará de los informes mensuales del INEI, disponibles en su biblioteca virtual, que además contienen la primera cifra publicada de cada mes. Para disponer de una historia larga en formato descargable se usará también la interfaz de programación (API) de BCRPData. Estas series no son una copia de las del INEI: las elabora el Departamento de Indicadores de la Actividad Económica del BCRP con información del INEI y de los ministerios de Agricultura, Energía y Minas y de la Producción, según los metadatos de cada serie. Por ello, antes de utilizarlas se verificará mes a mes su coincidencia con las cifras del INEI y, si hubiera diferencias, prevalecerá la cifra del INEI. En el total nacional la coincidencia ya se observa: para julio de 2026, BCRPData registra 3,56 %, la misma variación difundida por el INEI.

El INEI aporta además una predictora propia: el informe Avance Coyuntural de la Actividad Económica, que se publica alrededor de 30 días después del cierre del mes con indicadores como la producción de electricidad, el consumo interno de cemento y la pesca. Como se difunde unos quince días antes que el Informe Técnico, permite actualizar la estimación del mes anterior con información oficial. La Tabla 2 resume las fuentes.

Tabla 2. Fuentes de datos

Fuente	Variables	Frecuencia y disponibilidad	Estado
INEI, Informe Técnico de Producción Nacional	Variable objetivo: producción nacional y nueve sectores; primera cifra publicada de cada mes	Mensual; día 15 del segundo mes posterior	Disponible en la biblioteca virtual del INEI
INEI, Avance Coyuntural de la Actividad Económica	Indicadores sectoriales adelantados (electricidad, cemento, pesca, entre otros)	Mensual; unos 30 días tras el cierre	Por descargar (S1)
BCRPData	Series de producción elaboradas por el BCRP con datos del INEI y de los ministerios, desde 1994, y 42 series de apoyo por producto	Mensual; descarga por API	Se verificará su coincidencia con el INEI
BCRPData	Producción de electricidad, IGV interno, despacho de cemento y precios de metales	Mensual, de 7 a 12 días tras el cierre; metales, diaria	Por descargar (S1)
COES	Generación eléctrica diaria	Diaria, al día siguiente	Por probar (S1)
NOAA e IGP-ENFEN	Temperatura del mar (región Niño 1+2) e ICEN	Semanal y mensual	Descarga directa
PRODUCE	Temporada de pesca de anchoveta (abierta o cerrada) y desembarques	Según resolución ministerial; diaria	Por verificar (S1)
ENFEN	Fechas de inicio, fin y magnitud de los episodios de 2017, 2023 y 2026	Por episodio	Por codificar (S1)

Las diez series objetivo (códigos BCRPData PN01713AM, PN01716AM, PN01717AM, PN01720AM y PN01723AM a PN01728AM) se complementan con 42 series de apoyo: 14 de minería e hidrocarburos por metal, 13 de pesca por especie, 8 de los principales cultivos y 7 de las principales ramas manufactureras. No se reportan; se incluyen porque un modelo global mejora al aprender de más series similares, y se eligieron por tener datos continuos desde 1995 y peso dentro de su sector.

Para evitar la fuga de información, es decir, que el modelo use datos no disponibles al momento de estimar, se aplican cuatro reglas. Primero, solo se emplean predictoras que se publican antes que la cifra oficial; por ello se excluyen las exportaciones, cuyo rezago es similar al de la producción. Segundo, el IGV interno se asigna al mes anterior al de su recaudación, porque

corresponde a las ventas de ese mes. Tercero, no se usan series derivadas de la propia producción, como el PBI desestacionalizado. Cuarto, cada descarga se guarda con su fecha. Los meses de 2020 y 2021 se identifican con una variable indicadora por la pandemia.

3.2 Metodología

La Figura 1 resume el procedimiento. Los datos se almacenan en una base única; a partir de ellos se calculan el índice diario de electricidad y las variables de temperatura del mar, que ingresan como predictoras al modelo de estimación. Los resultados se presentan en un tablero y, cuando el INEI publica la cifra oficial, se registra el error del modelo. Los términos técnicos se definen en el Anexo.

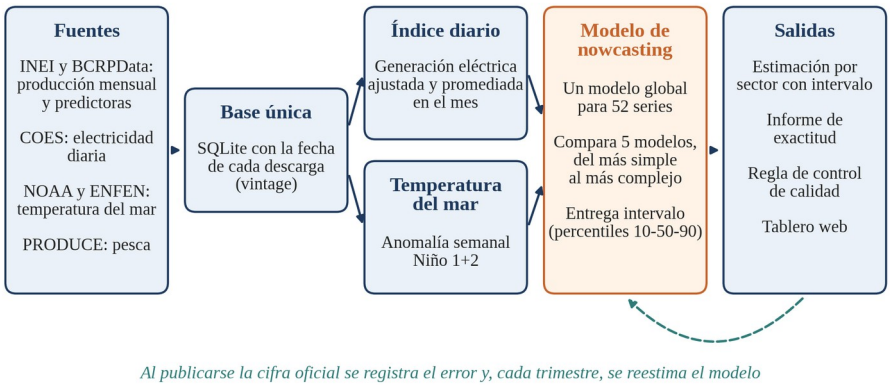


Figura 1. Procedimiento del indicador. Fuente: elaboración propia.

Paso 1. Almacenamiento de los datos. Un programa escrito en Python, que se ejecuta automáticamente una vez al día, descarga la información nueva de cada fuente y la guarda en una base de datos SQLite junto con la fecha de descarga.

Paso 2. Índice diario de actividad (OE3). La generación eléctrica de cada día se ajusta por el día de la semana y los feriados, y se compara con el mismo día del año anterior. Para el mes *m*, con *d* días transcurridos, el índice es el promedio de esas variaciones diarias:

$$E_m(d) = \frac{1}{d}\sum_{j=1}^{d}\left[\ln \tilde{g}_{m,j} - \ln \tilde{g}_{m-12,j}\right] \times 100 \qquad (1)$$

donde $\tilde{g}_{m,j}$ es la generación ajustada del día *j* del mes *m*. Se utiliza el promedio para que el índice sea comparable en cualquier momento del mes, con independencia del número de días observados. Al cierre del mes, E_m se aproxima a la variación interanual de la generación eléctrica mensual.

Paso 3. Modelo de estimación (OE1). Para cada serie *i*, mes *t* y fecha de estimación *d*, el modelo estima los percentiles 10, 50 y 90 de la variación interanual:

$$\hat{y}^{(q)}_{i,t|d} = f_\theta(y_{i,t-k_d}, \ldots, y_{i,t-k_d-11};\ \mathbf{x}_{t|d};\ \mathbf{T}_{t|d};\ s_i), \quad k_d \in \{2,3\}, \quad q \in \{0.1, 0.5, 0.9\} \qquad (2)$$

donde $y_{i,t-k}$ son los valores pasados de la serie, $\mathbf{x}_{t|d}$ es el conjunto de predictoras disponibles en la fecha *d* (índice diario, IGV, cemento, metales, temporada de pesca y, cuando ya se publicó, el Avance Coyuntural del INEI), $\mathbf{T}_{t|d}$ es el conjunto de variables de temperatura del mar (la anomalía semanal de la región Niño 1+2 y su cambio en tres meses) y s_i identifica la serie. El rezago k_d corresponde a la última cifra oficial publicada en la fecha *d*: como el INEI publica hacia el día 15 del segundo mes posterior, durante el mes *t* la última cifra disponible es la de *t*−3 hasta el día 15 y la de *t*−2 a partir de esa fecha. El percentil 50 es la estimación puntual, y los percentiles 10 y 90 delimitan un intervalo del 80 %. Cada serie se normaliza con la media y la desviación estándar de su periodo de entrenamiento, es decir, de los meses anteriores al mes evaluado que el modelo utiliza para aprender. Los percentiles se estiman minimizando la pérdida *pinball*, que penaliza de forma distinta las estimaciones situadas por encima y por debajo del valor observado:

$$L_q(y, \hat{y}^{(q)}) = \max\{q(y - \hat{y}^{(q)}),\ (q-1)(y - \hat{y}^{(q)})\} \qquad (3)$$

Se comparan cinco modelos ordenados de menor a mayor complejidad (Tabla 3). Un modelo más complejo solo se justifica si reduce el error respecto del anterior.

Tabla 3. Modelos comparados

Modelo	Descripción	Tipo
Persistencia	La estimación es la última variación interanual publicada.	Referencia
Electricidad	La estimación es el índice de la ecuación (1).	Referencia
Autorregresivo (AR)	Regresión lineal de la serie sobre sus doce valores anteriores, a partir del rezago k_d.	Referencia
LightGBM global	Suma de árboles de decisión estimada con las 52 series a la vez.	Aprendizaje automático

Modelo	Descripción	Tipo
TFT global	Red neuronal con atención estimada con las 52 series.	Aprendizaje automático

Cada modelo global se estima con las 9 series sectoriales y con las 52 series, para comprobar si las series de apoyo mejoran la estimación. Los hiperparámetros se eligen con Optuna (Akiba et al., 2019) dentro de un rango definido de antemano, y la contribución de cada predictora se mide con valores SHAP en LightGBM (Lundberg & Lee, 2017) y con los pesos de selección de variables del TFT.

Como con muestras pequeñas los intervalos no suelen alcanzar la cobertura esperada, se aplica la calibración conforme de cuantiles (Romano et al., 2019), que usa los errores de un periodo posterior al de entrenamiento para ajustar el ancho del intervalo hasta que contenga la cifra observada en el 80 % de los casos. El periodo de calibración se actualiza en cada estimación y la cobertura se informa por separado para los meses con y sin El Niño.

Paso 4. Aporte de la temperatura del mar (OE2). Cada modelo se estima con y sin las variables de temperatura del mar **T**, y se compara su error en los meses de cada episodio *E*, según las fechas establecidas por el ENFEN. La ganancia se define como la reducción porcentual de la raíz del error cuadrático medio (RMSE) al incluir **T**:

$$G_E = 1 - \frac{\mathrm{RMSE}_E(\text{con } \mathbf{T})}{\mathrm{RMSE}_E(\text{sin } \mathbf{T})} \tag{4}$$

donde RMSE_E se calcula solo con los meses del episodio *E*. Por ejemplo, una ganancia de 0,10 indica que la temperatura del mar reduce el error en 10 %. Se espera una mayor ganancia en 2023, cuando el calentamiento del mar afectó principalmente a la pesca, que en 2017, cuando los daños se debieron sobre todo a las lluvias en la costa norte. También se verifica que incluir **T** no aumente el error en los meses sin El Niño. El ICEN, cuyo valor más reciente es provisional, se utiliza únicamente para delimitar los episodios.

Paso 5. Aplicación en tiempo real y control de calidad (OE2). La estimación de agosto de 2026 se registrará en la primera semana del proyecto, antes de que el INEI publique la cifra a mediados de octubre, con un modelo autorregresivo y el índice de electricidad; si la descarga del COES aún no funciona, se usará la serie mensual de electricidad del BCRP. Cada estimación se guarda en un repositorio Git, que deja constancia de su fecha. Como la cifra de julio ya está publicada, este ejercicio evalúa la exactitud pero no la anticipación, que se evaluará con setiembre: su estimación se registrará hacia el 12 de octubre y se actualizará con el modelo completo en la cuarta semana.

La misma comparación sirve como control de calidad. Una cifra se marca para revisión cuando queda fuera del intervalo estimado:

$$\mathrm{Alerta}_{i,t} = 1 \quad \text{si} \quad y_{i,t}^{\mathrm{INEI}} \notin \left[\hat{y}_{i,t}^{(0.1)},\ \hat{y}_{i,t}^{(0.9)}\right] \tag{5}$$

Con un intervalo del 80 %, alrededor del 20 % de las cifras quedará fuera por construcción, de modo que la regla debe validarse. Para ello se compararán las primeras cifras publicadas de al menos los últimos 24 informes con sus valores revisados, y se verificará si las cifras marcadas fueron las que más se corrigieron después.

Paso 6. Operación del sistema. El indicador se actualiza de forma periódica, como se describe en la Tabla 4. Los resultados se muestran en un tablero web (Streamlit) con la estimación vigente por sector, el error según el día del mes, el desempeño durante El Niño y el historial frente a las cifras oficiales. Las tareas se ejecutan automáticamente con GitHub Actions, un servicio gratuito que corre los programas en fechas fijas.

Tabla 4. Operación periódica del sistema

Frecuencia	Tarea
Diaria y semanal	Descargar los datos nuevos (electricidad y metales cada día; temperatura del mar cada semana) y recalcular la estimación del mes en curso.
Mensual (día 12)	Registrar la estimación del mes anterior con toda la información disponible (retroproyección).
Mensual (día 15)	Al publicarse la cifra oficial, calcular el error y aplicar la regla de control de calidad.
Mensual (día 30)	Actualizar la estimación del mes anterior con el Avance Coyuntural del INEI.
Trimestral	Volver a estimar el modelo con los datos nuevos, o antes si el error de los últimos tres meses supera su percentil 90 histórico.

3.3 Validación, robustez y durabilidad

La evaluación utiliza validación de origen móvil: el modelo se entrena con los datos disponibles hasta un mes, estima el mes siguiente y el procedimiento se repite avanzando un mes cada vez, entre 2010 y 2026. En cada paso solo se emplean las cifras que estaban publicadas en la fecha correspondiente. La exactitud se mide con el RMSE y el error absoluto medio (MAE), por sector y por día del mes; la calidad de los intervalos, con la pérdida *pinball* y la cobertura; y la significancia de las diferencias entre modelos, con la prueba de Diebold y Mariano (1995). La ganancia de la temperatura del mar se evalúa con la ecuación (4).

Como las series históricas están revisadas, la evaluación se repite con las primeras cifras publicadas por el INEI, así como con distintas semillas aleatorias, con y sin los meses de pandemia y con intervalos del 80 % y del 90 %. La durabilidad se apoya en fuentes estables, reglas de datos escritas, control de versiones y documentación que permita al INEI operar el indicador cada mes.

4. Resultados esperados

Tabla 5. Productos finales y utilidad para el INEI

Producto	Descripción	Utilidad para la DTIE
Indicador adelantado	Estimación de la producción nacional y de sus nueve sectores con un intervalo del 80 %, disponible unos 30 días antes de la cifra oficial	Referencia temprana del mes que se está midiendo
Informe de exactitud	Error de cada modelo por sector y por día del mes, con la prueba de Diebold y Mariano	Conocer en qué sectores la estimación es confiable
Índice diario de actividad	Serie diaria basada en la generación eléctrica, con su ficha metodológica	Primera señal de actividad dentro del mes
Estudio de El Niño	Ganancia de la temperatura del mar en 2017 y 2023 y estimaciones registradas de agosto y setiembre de 2026	Medición más precisa durante el evento en curso
Regla de control de calidad	Cifras marcadas para revisión, validadas con las correcciones posteriores	Priorizar la revisión antes de publicar
Tablero y código	Tablero web, base de datos y programas documentados	Operación mensual sin descargas manuales

Salvaguardas. Toda estimación se presenta como no oficial, junto con su intervalo, su fecha de corte y el error histórico del modelo. El sistema se instala de forma local y no expone bases de datos.

5. Limitaciones del Proyecto Integrador

Tabla 6. Limitaciones y estrategias

Limitación	Estrategia
Muestra corta (unas 380 observaciones por serie) para modelos de aprendizaje automático	Modelo global con 52 series y comparación con referencias simples
Solo dos episodios históricos de El Niño Costero	Resultados presentados como estudio de caso, sin inferencia estadística
Las series históricas de BCRPData están revisadas y combinan datos del INEI y de los ministerios	Verificar su coincidencia con el INEI mes a mes (prevalece la cifra del INEI) y comparar con las primeras cifras de al menos 24 informes
La temperatura del mar no refleja las lluvias, principal daño en 2017	Incorporar la precipitación del SENAMHI como primera extensión
Intervalos con cobertura distinta a la esperada	Calibración conforme y reporte de la cobertura observada
Datos de desembarques de PRODUCE con poca historia	Usar solo la variable de temporada de pesca, disponible desde años atrás
Descarga diaria del COES no automatizada a tiempo	Usar la serie mensual de electricidad del BCRP
Poca experiencia del equipo con el TFT	Librerías de alto nivel; si no converge, reemplazarlo por N-HiTS (Challu et al., 2023)

Extensiones. Con más tiempo y recursos, el proyecto podría incorporar la precipitación diaria del SENAMHI, indicadores construidos a partir de noticias (Kalamara et al., 2022) y los catorce sectores que publica el INEI.

6. Cronograma (diagrama de Gantt, cinco semanas)

Tabla 7. Roles del equipo

Rol	Integrante	Responsabilidad principal
R1 · Datos	Calle Rentería, C. P.	Reglas de datos, descarga de las series, índice diario, base de datos y automatización
R2 · Modelos de aprendizaje automático	Ramírez Santos, M. Á.	Preparación de datos, LightGBM, TFT, Optuna y SHAP
R3 · Evaluación y El Niño	Shapiama De La Cruz, M.	Modelos de referencia, validación, calibración, estudio de El Niño y estimaciones en tiempo real
R4 · Datos climáticos y tablero	Mendizábal Huanca, L. Á.	Temperatura del mar, fechas del ENFEN, primeras cifras del INEI y tablero web

Tabla 8. Diagrama de Gantt

Tarea	Rol	S1	S2	S3	S4	S5
Reglas de datos y descarga de las series del INEI y del BCRP	R1	■	■			
Estimación de agosto con el modelo mínimo y registro en Git	R3 · R1	■				
Preparación de los datos para los modelos (formato largo y rezagos)	R2	■	■			
Temperatura del mar, fechas del ENFEN y temporada de pesca	R4	■	■			
Descarga diaria del COES e índice diario de actividad	R1	■	■			
Referencias: persistencia, electricidad y autorregresivo	R3		■			
Primeras cifras de al menos 24 informes del INEI	R4		■			
Estimación de setiembre, versión 1 (12 de octubre)	R3 · R4		■			
LightGBM global y prueba con 9 y 52 series	R2		■	■		
TFT global	R2			■	■	
Calibración y evaluación de origen móvil	R3			■	■	
Estudio de El Niño 2017 y 2023	R3 · R2			■	■	
Curva de error según el día del mes	R1 · R3			■		
Tablero web	R4		■	■	■	
Automatización con GitHub Actions	R1				■	
Estimación de setiembre, versión 2, y validación de la regla de control	R3 · R4				■	■
Integración y pruebas	Todos				■	■
Informe final y sustentación	Todos				■	■

Azul oscuro: trabajo principal; azul claro: apoyo. Todos los integrantes tienen tareas en cada semana. **Hitos:** al final de la semana 1, estimación de agosto registrada antes de la cifra oficial; semana 2, flujo completo con un modelo provisional y estimación de setiembre registrada; semana 3, LightGBM evaluado; semana 4, TFT calibrado y estudio de El Niño; semana 5, sistema integrado, informe y sustentación.

7. Respuesta a comentarios

Esta versión mantiene los cambios de la ronda anterior: el proyecto se centra en la medición, se retiraron los modelos econométricos y el análisis de shocks, y se incorporaron El Niño y la temperatura del mar. La Tabla 9 resume cómo se atendieron los comentarios sobre la versión final.

Tabla 9. Comentarios recibidos y cambios realizados

Comentario	Cambio realizado	Sección
Redacción telegráfica, informal o con apariencia de texto automático	El documento se reescribió en prosa continua; cada concepto se define al introducirse y se eliminaron las frases sueltas	Todas
Mucho texto; no respeta los límites de extensión	Cada sección se ajustó a su límite de páginas y se retiró el índice	Todas
Título muy largo	El subtítulo se redujo a «Nowcasting sectorial con aprendizaje automático y temperatura del mar»	Portada

Comentario	Cambio realizado	Sección
No se usan datos del INEI	La variable objetivo y las primeras cifras se toman de los informes del INEI, y el Avance Coyuntural del INEI se incorpora como predictora. BCRPData, que combina datos del INEI y de los ministerios, solo se usa tras verificar su coincidencia con el INEI	3.1
Relación entre la estimación y 2017; P4 y la frase sobre los resultados no se entendían	Los objetivos se reorganizaron en tres; El Niño (2017, 2023 y 2026) se agrupa en el OE2 y se reescribió la contribución	1
Conceptos usados antes de introducirlos	La revisión de literatura define nowcasting, aprendizaje automático, modelo global, LightGBM y TFT antes de usarlos	2
Índice *k* en la ecuación (1), promedio, periodo de entrenamiento, **T** y G_E sin definir	El día se denota *j*, se justifica el promedio y se definen el periodo de entrenamiento, **T** y la ganancia	3.2
Percentiles	Se usan los términos percentil 10, 50 y 90	3.2
El funcionamiento del sistema no quedaba claro	La Tabla 4 describe las tareas diarias, semanales, mensuales y trimestrales	3.2
Integrantes sin tareas en algunas semanas	El cronograma asigna tareas a todos los integrantes en cada semana	6
Glosario sin definiciones autocontenidas	Cada término se define de forma completa y, cuando corresponde, con su fórmula	Anexo

Dudas finales. (1) ¿Sería posible que la DTIE compartiera cifras preliminares internas para probar la regla de control en condiciones reales? (2) ¿Es adecuado un intervalo del 80 % para el uso institucional o convendría uno del 90 %?

Referencias

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 2623–2631).

Bok, B., Caratelli, D., Giannone, D., Sbordone, A. M., & Tambalotti, A. (2018). Macroeconomic nowcasting and forecasting with big data. *Annual Review of Economics, 10*, 615–643. https://doi.org/10.1146/annurev-economics-080217-053214

Cashin, P., Mohaddes, K., & Raissi, M. (2017). Fair weather or foul? The macroeconomic effects of El Niño. *Journal of International Economics, 106*, 37–54.

Chakraborty, C., & Joseph, A. (2017). *Machine learning at central banks* (Staff Working Paper N.° 674). Bank of England.

Challu, C., Olivares, K. G., Oreshkin, B. N., Garza, F., Mergenthaler-Canseco, M., & Dubrawski, A. (2023). N-HiTS: Neural hierarchical interpolation for time series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence, 37*(6), 6989–6997.

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics, 13*(3), 253–263.

Eurostat. (2017). *European statistics code of practice for the national statistical authorities and Eurostat* (revisado). Comité del Sistema Estadístico Europeo.

Flores, J., Gonzaga, B., Ruelas-Huanca, W., & Tang, J. (2024). *Nowcasting Peruvian GDP with machine learning methods* (Documento de Trabajo N.° 2024-019). Banco Central de Reserva del Perú.

Giannone, D., Reichlin, L., & Small, D. (2008). Nowcasting: The real-time informational content of macroeconomic data. *Journal of Monetary Economics, 55*(4), 665–676.

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735–1780.

Kalamara, E., Turrell, A., Redl, C., Kapetanios, G., & Kapadia, S. (2022). Making text count: Economic forecasting using newspaper text. *Journal of Applied Econometrics, 37*(5), 896–919.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems, 30*, 3146–3154.

Lewis, D. J., Mertens, K., & Stock, J. H. (2022). Measuring real activity using a weekly economic index. *Journal of Applied Econometrics, 37*(4), 667–687.

Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting, 37*(4), 1748–1764.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*, 4765–4774.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting, 36*(1), 54–74.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting, 38*(4), 1346–1364.

Montero-Manso, P., & Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. *International Journal of Forecasting, 37*(4), 1632–1653.

Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems, 32*.

Tenorio, J., & Perez, W. (2024). *GDP nowcasting with machine learning and unstructured data* (Documento de Trabajo N.° 2024-003). Banco Central de Reserva del Perú.

Fuentes de datos

Banco Central de Reserva del Perú. (2026). *BCRPData: Series estadísticas* [Base de datos]. https://estadisticas.bcrp.gob.pe/estadisticas/series/

Comité de Operación Económica del Sistema Interconectado Nacional. (2026). *Generación y demanda diaria del SEIN* [Conjunto de datos]. https://www.coes.org.pe/Portal/portalinformacion/generacion

ENFEN [Comisión Multisectorial encargada del Estudio Nacional del Fenómeno El Niño]. (2026). *Comunicado oficial ENFEN N.° 16-2026: Alerta de El Niño Costero* (14 de setiembre). https://enfen.imarpe.gob.pe/download/comunicado-oficial-enfen-n-16-2026/

Instituto Geofísico del Perú & ENFEN. (2026). *Índice Costero El Niño (ICEN), serie mensual 1950–2026* [Conjunto de datos]. http://met.igp.gob.pe/datos/ICEN.txt

Instituto Nacional de Estadística e Informática. (2026). *Informe Técnico: Avance Coyuntural de la Actividad Económica* [Boletines mensuales]. INEI.

Instituto Nacional de Estadística e Informática. (2026). *Informe Técnico: Producción Nacional* [Boletines mensuales]. https://m.inei.gob.pe/biblioteca-virtual/boletines/produccion-nacional/1/

Instituto Nacional de Estadística e Informática. (2026, 15 de setiembre). *Producción nacional creció 3,56 % en julio de 2026* [Nota de prensa]. https://www.gob.pe/institucion/inei/noticias/1444369-produccion-nacional-crecio-3-56-en-julio-de-2026

NOAA Climate Prediction Center. (2026). *Weekly OISST anomalies, Niño regions* [Conjunto de datos]. https://www.cpc.ncep.noaa.gov/data/indices/

Anexo. Glosario de términos técnicos

Término	Definición
Anomalía de temperatura del mar	Diferencia entre la temperatura superficial del mar observada en una zona y su promedio histórico para la misma época del año. Un valor positivo indica que el mar está más cálido de lo normal.
API (interfaz de programación de aplicaciones)	Servicio de una institución que entrega datos a un programa informático mediante solicitudes estandarizadas, sin necesidad de descargarlos manualmente desde una página web.
Aprendizaje automático	Conjunto de métodos estadísticos y computacionales que estiman la relación entre una variable y sus predictoras a partir de los datos, sin fijar de antemano la forma de esa relación.
Autorregresivo (AR)	Modelo lineal que estima una serie a partir de sus propios valores pasados: $\hat{y}(t) = c + \varphi_1 \cdot y(t-k) + \ldots + \varphi_{12} \cdot y(t-k-11)$, donde k es el rezago de la última cifra publicada y c y φ son parámetros estimados por mínimos cuadrados.
Avance Coyuntural de la Actividad Económica	Informe mensual del INEI que se publica alrededor de 30 días después del cierre del mes, antes del Informe Técnico de Producción Nacional, con indicadores sectoriales como la producción de electricidad, el consumo interno de cemento y la pesca.
Calibración conforme de cuantiles	Procedimiento que corrige el ancho de un intervalo usando datos no empleados en el entrenamiento. Para cada observación de calibración se calcula $s = \max(\hat{y}_{10} - y, y - \hat{y}_{90})$; el intervalo final es $[\hat{y}_{10} - Q, \hat{y}_{90} + Q]$, donde Q es el percentil 80 de los valores s. Así, el intervalo contiene la cifra observada en cerca del 80 % de los casos.
Cobertura del intervalo	Proporción de meses en que la cifra oficial quedó dentro del intervalo estimado. Para un intervalo del 80 %, la cobertura esperada es 0,80.
COES y SEIN	El Comité de Operación Económica del Sistema Interconectado Nacional (COES) coordina la operación del Sistema Eléctrico Interconectado Nacional (SEIN), que abastece de electricidad a la mayor parte del país, y publica a diario su generación.
Commit	Registro de un cambio en un repositorio Git que guarda el contenido, el autor y la fecha. Sirve como constancia de que una estimación se hizo antes de conocerse la cifra oficial.
Diebold y Mariano (prueba de)	Prueba estadística que compara la exactitud de dos modelos. Con los errores de pronóstico e_1 y e_2 se calcula $d(t) = e_1(t)^2 - e_2(t)^2$; el estadístico es $DM = \bar{d} / \sqrt{(\hat{V}(\bar{d}))}$, que sigue aproximadamente una distribución normal estándar. Un valor significativo indica que un modelo es más exacto que el otro.
Dropout	Técnica de entrenamiento de redes neuronales que desactiva al azar una fracción de las neuronas en cada iteración, para evitar que la red memorice los datos de entrenamiento.
DTIE	Dirección Técnica de Indicadores Económicos del INEI, encargada de elaborar el Informe Técnico de Producción Nacional.
Early stopping (parada temprana)	Regla que detiene el entrenamiento de un modelo cuando su error en un periodo de validación deja de disminuir, para evitar el sobreajuste.
El Niño Costero	Calentamiento anómalo del mar frente a la costa peruana, en la región Niño 1+2. El ENFEN lo declara cuando el ICEN indica condiciones cálidas durante al menos tres meses consecutivos y clasifica su magnitud en débil, moderada, fuerte o extraordinaria.
Error de pronóstico	Diferencia entre el valor observado y el estimado: $e(t) = y(t) - \hat{y}(t)$.
Fuga de información	Error metodológico en el que un modelo utiliza datos que no estaban disponibles en la fecha de la estimación. Hace que el error medido sea menor que el que se obtendría en la práctica.
Ganancia de la temperatura del mar (G)	Reducción porcentual del RMSE al añadir las variables de temperatura del mar: $G = 1 - \text{RMSE(con T)} / \text{RMSE(sin T)}$, calculada con los meses de un episodio de El Niño.
GitHub Actions	Servicio gratuito de GitHub que ejecuta programas de forma automática en fechas u horarios definidos.
Hiperparámetro	Valor que se fija antes de entrenar un modelo y que controla su funcionamiento, como el número de árboles en LightGBM o el número de neuronas en una red. A diferencia de los parámetros, no se estima directamente con los datos.
ICEN (Índice Costero El Niño)	Promedio de tres meses consecutivos de la anomalía mensual de la temperatura del mar en la región Niño 1+2: $ICEN(t) = [A(t-1) + A(t) + A(t+1)] / 3$. Lo calcula el IGP para el ENFEN; su valor más reciente es provisional porque requiere el dato del mes siguiente.

Término	Definición
IGV interno	Impuesto General a las Ventas recaudado por operaciones dentro del país. Se usa como aproximación del consumo; la recaudación de un mes corresponde a las ventas del mes anterior.
Intervalo de predicción	Rango de valores entre dos percentiles estimados, por ejemplo el 10 y el 90, dentro del cual se espera que se encuentre la cifra observada con una probabilidad dada, en este caso 80 %.
LightGBM	Método de aprendizaje automático que estima una suma de árboles de decisión, $\hat{y} = f_1(x) + f_2(x) + \ldots + f_M(x)$, donde cada árbol se ajusta a los errores que dejan los árboles anteriores.
LSTM (memoria de corto y largo plazo)	Tipo de red neuronal recurrente que procesa los datos en orden temporal y conserva información de periodos anteriores mediante compuertas que deciden qué recordar y qué olvidar.
MAE (error absoluto medio)	Promedio del valor absoluto de los errores: $MAE = (1/n)\ \Sigma\ \lvert y(t) - \hat{y}(t)\rvert$.
Modelo global	Modelo único que se entrena con varias series a la vez, en lugar de estimar un modelo distinto para cada serie. Comparte información entre series con comportamiento similar.
Niño 1+2 (región)	Zona del océano Pacífico ubicada entre 0° y 10° de latitud sur y entre 80° y 90° de longitud oeste, frente a las costas de Perú y Ecuador.
Normalización	Transformación de una serie para expresarla en una escala común: $z = (x - \mu) / \sigma$, donde μ y σ son la media y la desviación estándar del periodo de entrenamiento.
Nowcasting	Estimación del valor de una variable en el presente o en el pasado inmediato, cuando la cifra oficial aún no ha sido publicada, usando información disponible antes que ella.
Optuna	Programa que busca automáticamente la combinación de hiperparámetros con la que un modelo obtiene el menor error en un periodo de validación.
Percentil	Valor por debajo del cual se encuentra un porcentaje dado de los resultados posibles. El percentil 10 deja por debajo el 10 % y el percentil 90, el 90 %.
Pérdida pinball	Medida de error usada para estimar el percentil q: $L = q\cdot(y - \hat{y})$ si $y \geq \hat{y}$, y $L = (1 - q)\cdot(\hat{y} - y)$ si $y < \hat{y}$. Su promedio se minimiza cuando $\hat{y}$ es el percentil q de la distribución.
Periodo de entrenamiento, calibración y evaluación	Partición de los datos en el tiempo. El periodo de entrenamiento se usa para estimar el modelo; el de calibración, posterior, para ajustar el intervalo; y el de evaluación, siempre posterior a ambos, para medir el error.
Persistencia	Estimación que repite la última cifra publicada: $\hat{y}(t) = y(t-k)$, donde k es el rezago de esa cifra.
Predictora	Variable que el modelo utiliza para estimar la variable objetivo, por ejemplo la generación eléctrica para estimar la producción.
Primera cifra publicada	Valor que el INEI difunde por primera vez para un mes, antes de las revisiones que pueden realizarse en informes posteriores.
Retroproyección	Estimación de un mes ya concluido cuya cifra oficial aún no se publica. Dispone de más información que la estimación del mes en curso.
Rezago de publicación	Tiempo que transcurre entre el final del mes de referencia y la difusión de su cifra oficial.
RMSE (raíz del error cuadrático medio)	Raíz cuadrada del promedio de los errores al cuadrado: $RMSE = \sqrt{[(1/n)\ \Sigma\ (y(t) - \hat{y}(t))^2]}$. Penaliza más los errores grandes que el MAE.
SHAP (valores de Shapley)	Método que descompone una estimación en la contribución de cada predictora: $\hat{y} = \varphi_0 + \varphi_1 + \ldots + \varphi_p$, donde φ_0 es la estimación promedio y φ_j la contribución de la predictora j.
SQLite	Sistema de base de datos que almacena toda la información en un solo archivo y no requiere instalar un servidor.
Streamlit	Librería de Python para construir aplicaciones web interactivas, como tableros de visualización.
Temporada de pesca	Periodo, establecido por resolución ministerial de PRODUCE, en el que se autoriza la pesca de anchoveta en una zona. En este proyecto se representa con una variable que vale 1 si la temporada está abierta y 0 si está cerrada.

Término	Definición
TFT (Temporal Fusion Transformer)	Red neuronal para series de tiempo que combina capas LSTM con un mecanismo de atención, el cual asigna pesos a los periodos y variables más relevantes. Estima varios percentiles a la vez e informa la importancia de cada variable.
Validación de origen móvil	Forma de evaluar pronósticos en la que el modelo se entrena con los datos hasta un mes t, estima el mes t+1 y el procedimiento se repite avanzando un mes cada vez. Respeta el orden temporal de los datos.
Variación interanual	Cambio porcentual de una cifra respecto del mismo mes del año anterior: 100 × [Y(t) / Y(t−12) − 1]. Elimina el efecto de la estacionalidad.
Vintage	Versión de una base de datos tal como estaba disponible en una fecha determinada. Permite evaluar un modelo solo con la información que existía en ese momento.