PROGRAMA DE EXTENSIÓN UNIVERSITARIA: CIENCIA DEL DATO (PEU-CD)
INSTITUTO NACIONAL DE ESTADÍSTICA E INFORMÁTICA (INEI)

PROPUESTA FINAL DE PROYECTO INTEGRADOR

Indicador Adelantado de la Producción Nacional (IAPN)

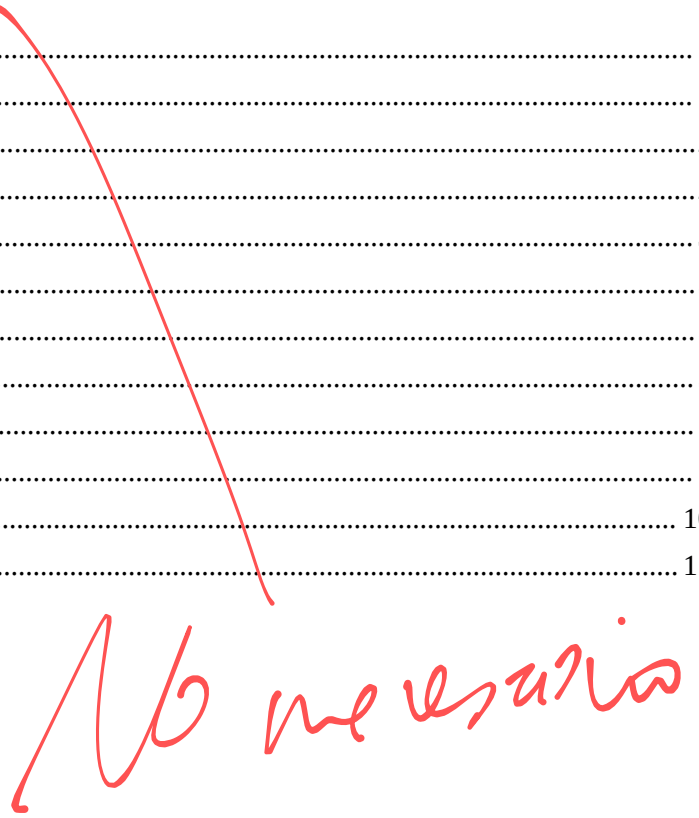
Nowcasting de la producción nacional mensual y sectorial con aprendizaje automático para series de tiempo y temperatura del mar, con exactitud medida, para el INEI frente a El Niño Costero 2026–2027

Integrantes:
Calle Rentería, Christopher Paul
Mendizábal Huanca, Luz Ángela
Ramírez Santos, Maykol Ángel
Shapiama De La Cruz, Marcia

Lima, Perú
Octubre de 2026

Índice

1. Motivación y justificación 1
2. Revisión inicial de literatura y marco teórico 1
3. Estrategia empírica 2
3.1 Fuentes de datos y acceso 2
3.2 Metodología: un solo flujo, siete pasos 3
3.3 Validación, robustez y durabilidad 5
4. Resultados esperados 5
5. Limitaciones del Proyecto Integrador 5
6. Cronograma (diagrama de Gantt, cinco semanas) 7
7. Respuesta a comentarios 7
Referencias 10
Anexo. Glosario de términos técnicos 11



1. Motivación y justificación

El INEI publica el Informe Técnico de Producción Nacional unos 45 días después del cierre de cada mes: el de julio de 2026 se difundió el 15 de setiembre y BCRPData lo incorporó el 17 (verificación del equipo, 20/09/2026). Esa latencia es el costo de una cifra certificada y no es un defecto; pero puede complementarse con una **estimación temprana cuya exactitud se mida y se publique**. Es lo que hacen las oficinas estadísticas que difunden estimaciones rápidas (*flash*) del producto, para las que la oportunidad y la exactitud son dimensiones de calidad que deben equilibrarse (Eurostat, 2017).

El problema es más urgente en 2026. El ENFEN mantiene la alerta de El Niño Costero, iniciado en marzo, y en su comunicado de setiembre consideró más probable una magnitud extraordinaria entre setiembre de 2026 y enero de 2027 (ENFEN, 2026). En estos episodios la producción cambia de forma abrupta —pesca, agro y manufactura primaria— y los modelos que extrapolan la tendencia fallan justo cuando la información temprana es más valiosa. Los episodios de 2017 y 2023 son dos ensayos naturales para medir ese problema y para evaluar si la temperatura del mar, que se observa cada semana, ayuda a corregirlo.

Objetivo general. Construir y evaluar el Indicador Adelantado de la Producción Nacional (IAPN): un *nowcast* de la producción nacional mensual —el indicador mensual del PBI que publica el INEI— y de la producción de sus nueve sectores, con intervalos de incertidumbre y exactitud medida, que pueda producirse antes de la publicación oficial y que mantenga su desempeño durante episodios de El Niño.

Tabla 1. Objetivos específicos y preguntas de investigación

Objetivo específico	Pregunta de investigación
OE1. Estimar la variación interanual de la producción nacional y de sus 9 sectores antes de la cifra oficial con modelos globales de aprendizaje automático para series de tiempo.	**P1.** ¿Cuánto reducen el error los modelos globales (LightGBM y TFT) frente a tres referencias simples: la persistencia, la variación de la electricidad tomada directamente como estimación y un autorregresivo? ¿Mejora la exactitud si se entrena con 52 series productivas en lugar de solo los 9 sectores?
OE2. Incorporar la temperatura del mar y medir su aporte durante episodios de El Niño.	**P2.** En los meses de El Niño Costero de 2017 y de 2023, ¿cuánto se reduce el error al añadir la temperatura del mar? ¿Por qué difiere el resultado entre ambos episodios?
OE3. Construir un índice diario de actividad con la generación eléctrica y medir cómo mejora la estimación a medida que avanza el mes.	**P3.** ¿Cómo disminuye el error del mes en curso conforme se acumulan días de información? ¿Desde qué día supera a la referencia?
OE4. Aplicar el sistema en tiempo real durante El Niño Costero 2026 y usarlo como señal de control de calidad.	**P4.** ¿Contuvo el intervalo la cifra oficial de agosto (y de setiembre) de 2026, con un nowcast registrado antes de su publicación? En la evaluación histórica, ¿con qué frecuencia la cifra oficial cae fuera del intervalo?

Necesidad del INEI y área interesada. El usuario principal es la **Dirección Técnica de Indicadores Económicos (DTIE)**, que elabora el Avance Coyuntural y el Informe Técnico de Producción Nacional. El sistema le ofrece tres usos: (i) una referencia interna temprana, con intervalo, del mes que se está midiendo; (ii) un **control de calidad**: si la cifra sectorial en preparación cae fuera del intervalo del modelo, la serie se marca para revisión antes del cierre; y (iii) la base técnica para una eventual estadística experimental de estimación rápida. El encuadre es complementario: no se propone publicar cifras no certificadas. La Dirección Nacional de Cuentas Nacionales es usuaria secundaria.

Contribución esperada. (1) Un nowcast sectorial con modelos globales y exactitud medida por sector y por día del mes, del que no identificamos evidencia pública previa en el Perú; (2) evidencia sobre si la temperatura del mar mejora la medición temprana durante El Niño; (3) un índice diario de actividad basado en electricidad, del que no identificamos un equivalente público; (4) una evaluación en tiempo real registrada antes de la cifra oficial; y (5) un proceso reproducible que el INEI puede operar. Ningún resultado invalida el proyecto: si el aprendizaje automático no supera a la referencia, eso se reporta como hallazgo.

2. Revisión inicial de literatura y marco teórico

Nowcasting y estadística oficial. Giannone et al. (2008) definen el *nowcasting* como la estimación del presente y del pasado inmediato de una variable de baja frecuencia a partir de datos de alta frecuencia que se publican antes que ella. Bok et al. (2018) documentan su institucionalización en bancos centrales y su paso a entornos de datos masivos. Para una oficina de estadística, el marco relevante es el de calidad: el Código de Buenas Prácticas de las Estadísticas Europeas trata la exactitud y la oportunidad como dimensiones separadas de la calidad estadística (Eurostat, 2017). Nuestro proyecto busca ganar oportunidad sin perder de vista la exactitud, que se mide y se publica.

Evidencia peruana. Tenorio y Perez (2024) proyectan el crecimiento mensual del PBI combinando indicadores estructurados con variables de sentimiento extraídas de texto; Flores et al. (2024) comparan doce métodos de aprendizaje automático con más de 170 predictores para el PBI total y no primario. Ambos trabajan sobre el agregado. El espacio vacante es la desagregación sectorial y el desempeño en episodios climáticos.

Aprendizaje automático para series de tiempo. El obstáculo para usar redes neuronales con datos macroeconómicos mensuales es la muestra corta (unas 380 observaciones por serie desde 1995). Montero-Manso y Hyndman (2021) muestran que un **modelo global** —un único modelo entrenado sobre un conjunto de series relacionadas— puede superar a los modelos individuales aun con series heterogéneas, porque el agrupamiento actúa como regularizador; las competencias M4 y M5 lo confirman empíricamente (Makridakis et al., 2020, 2022). Sobre esa base comparamos LightGBM, un método de árboles potenciados eficiente que dominó la competencia M5 (Ke et al., 2017), y el Temporal Fusion Transformer (TFT), que combina capas recurrentes LSTM (Hochreiter & Schmidhuber, 1997) con atención y selección de variables, produce cuantiles y muestra qué variable pesó en cada estimación (Lim et al., 2021). Esta interpretabilidad importa en una institución que debe justificar cada cifra (Chakraborty & Joseph, 2017).

Alta frecuencia y clima. Lewis, Mertens y Stock (2022) construyen un índice semanal de actividad para EE. UU. con indicadores de alta frecuencia; adaptamos su lógica con la generación eléctrica, especialmente informativa en el Perú por el peso de la minería y la manufactura. Cashin, Mohaddes y Raissi (2017) documentan que El Niño tiene efectos macroeconómicos significativos y heterogéneos entre países, lo que justifica tratarlo como información relevante para medir la actividad de corto plazo y no solo como un riesgo narrativo. Como extensión, Kalamara et al. (2022) muestran que indicadores construidos a partir de texto periodístico mejoran el pronóstico macroeconómico.

Brecha. No se ha identificado evidencia pública de nowcasting sectorial peruano con modelos globales, de su desempeño durante El Niño ni de un índice diario de actividad. La evaluación se apoya en la validación de origen móvil y en la prueba de Diebold y Mariano (1995), práctica estándar para comparar pronósticos (Hyndman & Athanasopoulos, 2021).

3. Estrategia empírica

3.1 Fuentes de datos y acceso

Todas las fuentes son públicas y gratuitas. Todas se descargan por API o archivo directo, salvo los desembarques de PRODUCE, que pueden requerir descarga manual; por eso su plan B es una variable que no depende de ella. La Tabla 2 indica qué ya se tiene y qué se conseguirá.

Tabla 2. Fuentes de datos

Fuente	Variables	Frecuencia y rezago	Acceso	Estado
BCRPData (datos del INEI)	Producción nacional y 9 sectores (10 códigos, ver texto) y 42 series productivas de apoyo	Mensual, 1994–jul. 2026; ~45 días	API JSON	Verificado 20/09/2026
BCRPData	Electricidad mensual, IGV interno, despacho de cemento, precios de cobre, oro y zinc, términos de intercambio	Mensual (metales diarios); 7–12 días	API JSON	Por descargar (S1)
COES SINAC	Generación eléctrica diaria del SEIN	Diaria; 1 día	Descarga automatizada	Prueba en S1
ENFEN / IGP	Índice Costero El Niño (ICEN), media móvil de 3 meses; solo con rezago y para fechar episodios	Mensual desde 1950; el valor de *t* requiere *t*+1 y los recientes son provisionales	Archivo de texto	Descarga directa
NOAA (CPC)	Anomalía semanal de temperatura superficial del mar, regiones Niño 1+2 y 3.4 (predictora principal)	Semanal desde 1990; días	Archivo de texto	Descarga directa
PRODUCE	Desembarque de anchoveta (si hay historia suficiente). Plan B: temporada de pesca abierta o cerrada, variable binaria histórica tomada de las resoluciones ministeriales	Diaria o por resolución; la temporada se conoce de antemano	Web institucional; descarga manual	Por verificar (S1)
ENFEN (comunicados)	Fechas de inicio, fin y magnitud de El Niño Costero 2017, 2023 y 2026	Por evento	PDF	Por codificar (S1)

Las 52 series. Objetivo de reporte: producción nacional y nueve sectores (10 series; códigos BCRPData PN01713AM, PN01716AM, PN01717AM, PN01720AM y PN01723AM a PN01728AM). Apoyo al entrenamiento: 14 series de minería e hidrocarburos (por metal), 13 de pesca (por especie y destino), 8 de los cultivos de mayor peso del agro y 7 de las ramas de mayor peso de la manufactura (42 series). Criterio de inclusión: historia continua desde 1995 y peso dentro del sector. Solo se reportan las 10 series objetivo; las otras 42 son ejemplos adicionales de la dinámica productiva peruana de los que el modelo aprende.

Reglas del contrato de datos. (a) Ninguna predictora cuyo rezago de publicación iguale o supere al de la cifra oficial entra al modelo; por eso se excluyen las exportaciones tradicionales (41–45 días) y el canal externo se cubre con precios diarios de metales, que informan sobre precios más que sobre volumen; el volumen minero se aproxima con la electricidad y el pesquero con los desembarques. (b) El IGV interno se desplaza un mes, porque la recaudación de *t* corresponde a operaciones de *t*−1. (c) Lista negra contra la fuga de información: PBI desestacionalizado, sectores primarios y no primarios

y demanda interna nunca son predictoras. (d) Cada descarga se guarda con su fecha (*vintage*). Como BCRPData muestra cifras ya revisadas, el pseudo tiempo real histórico usa cifras revisadas; para los últimos 24 meses se recopilan a mano las primeras cifras publicadas en los Informes Técnicos. (e) Los meses de 2020–2021 se marcan con una variable indicadora de pandemia y sus errores se reportan por separado. Se adopta la taxonomía de nueve sectores del BCRP, que ofrece historia desde 1994 a costa de agrupar servicios.

3.2 Metodología: un solo flujo, siete pasos

Todos los componentes convergen en un único producto: el nowcast. La Figura 1 muestra el flujo; cada paso alimenta al siguiente y nada se estima en paralelo para otro fin.

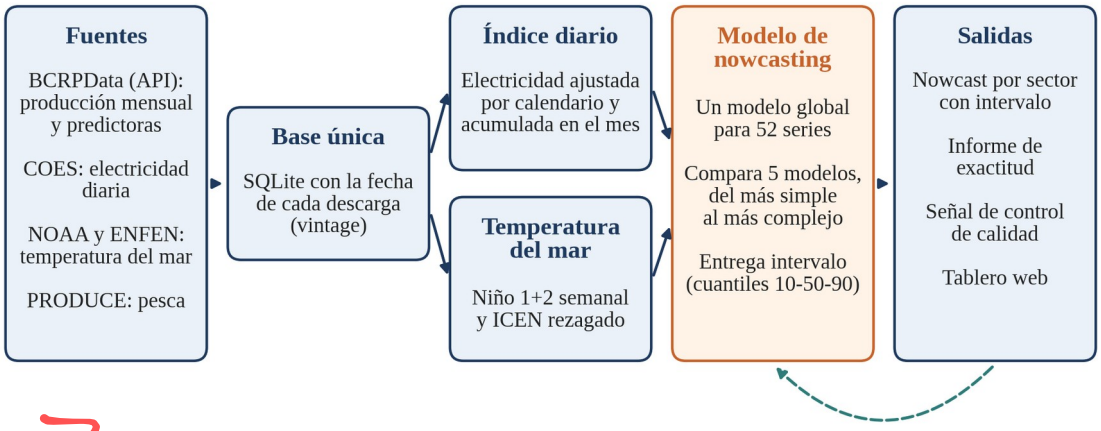


Figura 1. Flujo del sistema. Elaboración propia.

Los términos técnicos usados en esta sección se definen en el glosario del Anexo.

Paso 1. Ingesta automática. Un programa descarga cada día los datos nuevos (electricidad, metales, temperatura del mar) y cada mes las series del BCRP, y los guarda en una base SQLite con la fecha de descarga. Así se puede reconstruir qué sabía el sistema en cualquier día pasado.

Paso 2. Índice diario de actividad (OE3). La generación eléctrica diaria se ajusta por día de la semana y feriados, y se compara con el día equivalente del año anterior. El índice del mes m con d días transcurridos es el promedio de esas variaciones:

$$E_m(d) = \frac{1}{d}\sum_{k=1}^{d}[\ln \tilde{g}_{m,k} - \ln \tilde{g}_{m-12,k}] \times 100 \qquad (1)$$

donde $\tilde{g}$ es la generación ajustada. Al cerrar el mes, E aproxima la variación interanual de la generación eléctrica del mes. El índice entra al modelo del Paso 3 como una predictora más: no es un producto aislado.

Paso 3. Modelo de nowcasting (OE1). Para cada serie i y mes t, el modelo estima tres cuantiles de la variación interanual:

$$\hat{y}^{(q)}_{i,t|d} = f_\theta(y_{i,t-k_d}, \ldots, y_{i,t-k_d-11};\ \mathbf{x}_{t|d};\ \mathbf{T}_{t|d};\ s_i), \quad k_d \in \{2,3\}, \quad q \in \{0.1, 0.5, 0.9\} \qquad (2)$$

donde $\mathbf{x}$ son las predictoras disponibles en la fecha de estimación d (índice diario, IGV, cemento, metales, desembarques y temporada de pesca), $\mathbf{T}$ las variables de temperatura del mar y s el identificador de la serie. **Los rezagos propios empiezan en** k_d, el rezago de la última cifra oficial publicada en la fecha d (2 o 3 meses; ver Paso 4), y nunca en $t-1$, porque esa cifra aún no existe cuando se estima. **Preparación de las series:** todas se expresan en variación interanual, lo que elimina la estacionalidad y la mayor parte de la tendencia, y cada serie se normaliza con la media y la desviación estándar de su tramo de entrenamiento, para que las 52 series sean comparables. Los cuantiles 0,1 y 0,9 forman un intervalo del 80 % y el 0,5 es la estimación puntual. Los modelos con cuantiles se entrenan minimizando la pérdida *pinball*, que penaliza de forma asimétrica los errores por encima y por debajo de cada cuantil:

$$L_q(y, \hat{y}^{(q)}) = \max\{q(y - \hat{y}^{(q)}),\ (q-1)(y - \hat{y}^{(q)})\} \qquad (3)$$

Modelo global significa que un solo modelo aprende de las 52 series a la vez, en lugar de estimar uno por serie. *Escalera de modelos* significa que comparamos cinco modelos ordenados del más simple al más complejo (Tabla 3), con una regla sencilla: un modelo más complejo solo se justifica si reduce el error frente al anterior.

Tabla 3. Escalera de modelos

Nivel	Modelo	Qué hace, en una línea	Papel
0	Persistencia	Repite la última variación interanual publicada (de $t-2$ o $t-3$)	Piso mínimo

Nivel	Modelo	Qué hace, en una línea	Papel
1	Electricidad directa	Toma la variación interanual de la electricidad como estimación, sin estimar nada; es lo que usaría hoy un analista	Piso práctico
2	Autorregresivo (AR)	Proyecta en forma directa desde la última cifra publicada, con 12 rezagos	Referencia estadística
3	LightGBM global	Árboles de decisión que aprenden reglas a partir de rezagos y predictoras	Aprendizaje automático tabular
4	TFT global	Red con atención; elige variables, entrega cuantiles y muestra qué variable pesó	Modelo principal

Prueba de 9 frente a 52 series (antes llamada «ablación»). Cada modelo global se entrena dos veces: solo con los 9 sectores y con las 52 series. Si el error baja con 52, ampliar los datos ayuda; si sube, se reporta que las series de apoyo añaden ruido. Regularización: *dropout* y *early stopping*. **Calibración del intervalo:** con unas 380 observaciones por serie, los cuantiles de LightGBM y del TFT suelen quedar mal calibrados, por eso se aplica una calibración conforme de cuantiles (Romano, Patterson & Candès, 2019), que en un tramo de calibración posterior al de entrenamiento mide cuánto fallan los cuantiles y ajusta el ancho del intervalo para acercar su cobertura al 80 %. Como estos métodos suponen datos intercambiables, supuesto que se rompe en episodios como El Niño o la pandemia, la ventana de calibración es reciente y se mueve con el origen de evaluación, y la cobertura se reporta por separado en los meses de El Niño y fuera de ellos, antes y después de calibrar. **Ajuste de hiperparámetros:** búsqueda con Optuna (Akiba et al., 2019) sobre una grilla pequeña definida a priori y evaluada solo en el tramo de validación. **Interpretabilidad:** valores SHAP para LightGBM (Lundberg & Lee, 2017) y pesos de selección de variables para el TFT; si ambos modelos destacan las mismas predictoras, la estimación es más fácil de defender ante la DTIE. Software: Python, neuralforecast (PyTorch), lightgbm, optuna, shap, statsmodels y scikit-learn; entrenamiento en Google Colab.

Paso 4. Dos momentos de estimación y calendario de publicación. El sistema estima cada mes dos veces. Durante el mes en curso usa el índice diario, los metales, la pesca y la temperatura del mar (intervalo más ancho). Unos 12 días después del cierre, con el mes completo de electricidad y el despacho de cemento, produce la **retroproyección**, unos 30 días antes de la cifra oficial. La última cifra oficial disponible depende del día: como el INEI publica hacia el día 15 del segundo mes posterior, durante el mes t la más reciente es la de $t-3$ hasta el día 15 y la de $t-2$ después; en la retroproyección (hacia el día 12 de $t+1$) sigue siendo $t-2$. Por eso k_d vale 3 o 2, la persistencia repite la última cifra publicada y el AR proyecta desde ese rezago. En la validación se reconstruye, para cada fecha histórica, qué cifra oficial estaba publicada ese día. Ambos momentos se evalúan por separado, y la curva de error según el día del mes responde P3.

Paso 5. Módulo El Niño (OE2). La temperatura del mar entra al modelo como variable continua. La predictora principal es la anomalía semanal de la región Niño 1+2, la más oportuna, junto con su cambio en tres meses; el ICEN, cuyo valor más reciente es provisional por ser una media móvil de tres meses, solo entra con rezago y sirve para fechar episodios. Al ser continua, aporta información también en meses sin evento o con eventos débiles. Para medir su aporte se compara el modelo con y sin **T** en los meses de cada episodio E, según las fechas declaradas por el ENFEN.

$$G_E = 1 - \frac{\mathrm{RMSE}_E(\text{con } \mathbf{T})}{\mathrm{RMSE}_E(\text{sin } \mathbf{T})} \tag{4}$$

Un valor positivo indica que la temperatura del mar reduce el error. La comparación entre episodios es informativa: en 2017 el daño provino sobre todo de lluvias e inundaciones en la costa norte, mientras que en 2023 pesó más el calentamiento del mar sobre la pesca. La hipótesis es que **T** ayuda más en 2023 que en 2017; si se confirma, señala qué información adicional falta para episodios como el de 2017. La precipitación es la primera extensión: el ENFEN prevé lluvias sobre lo normal en la costa norte, con episodios de moderada a fuerte intensidad desde noviembre de 2026 (ENFEN, 2026). También se verifica que añadir **T** no empeore los meses normales.

Paso 6. Aplicación en tiempo real y señal de control de calidad (OE4). La cifra de agosto de 2026 se publicará hacia mediados de octubre, así que su nowcast se registra en la **semana 1** con un modelo mínimo —AR más el índice eléctrico— mediante un *commit* fechado en el repositorio; si la descarga diaria del COES aún no funciona, se usa la electricidad mensual del BCRP. Como julio ya está publicado, este caso solo anticipa unos 10 días: **valida exactitud, no anticipación**. Para demostrar la anticipación estándar de ~30 días, setiembre se registra dos veces sin sobrescribir: una primera versión hacia el 12 de octubre con el modelo disponible y una segunda con el modelo completo en S4. Al salir cada cifra oficial se calcula el error real. La misma comparación define la señal de control:

$$\mathrm{Alerta}_{i,t} = 1 \quad \text{si} \quad y_{i,t}^{\mathrm{INEI}} \notin \left[\hat{y}_{i,t}^{(0.1)},\ \hat{y}_{i,t}^{(0.9)}\right] \tag{5}$$

En operación, la DTIE aplicaría esta regla a su cifra preliminar antes del cierre. Para agosto y setiembre de 2026 solo se reporta si el intervalo contuvo o no la cifra oficial: con uno o dos meses no se puede estimar una frecuencia. Como un intervalo del 80 % bien calibrado marca por diseño cerca del 20 % de los meses (unas dos alertas al mes con 10 series), la alerta por sí sola no prueba utilidad. Por eso la señal se valida con las primeras cifras de los últimos 24 Informes Técnicos: se verifica si las cifras que cayeron fuera del intervalo fueron después las más revisadas. Si es así, la señal ayuda a la DTIE a priorizar revisiones; las alertas se ordenan por su distancia al intervalo.

Paso 7. El tablero y la operación continua. El instrumento es un tablero web (Streamlit) que lee la base del Paso 1 y muestra cuatro paneles: (a) nowcast vigente por sector, con intervalo y fecha de corte; (b) curva de exactitud según el día del mes; (c) panel El Niño, con la temperatura del mar y el desempeño del modelo en 2017, 2023 y 2026, y (d) historial de nowcasts frente a cifras oficiales, con las alertas. El sistema **sigue corriendo en el tiempo**: cada día se actualizan los datos y se recalcula el nowcast sin reentrenar; cada mes, cuando el INEI publica, se registra el error; y el modelo se reentrena cada tres meses o antes si el error de los últimos tres meses supera su percentil 90 histórico. Las tareas se programan con GitHub Actions (gratuito) y ningún nowcast se sobrescribe, de modo que el historial de aciertos y errores es auditable.

3.3 Validación, robustez y durabilidad

Tabla 4. Cómo se verifica cada objetivo

Objetivo	Verificación	Robustez y sensibilidad
OE1	Validación de origen móvil (ventana creciente; evaluación 2010–2026; nunca aleatoria) con los rezagos disponibles en cada fecha. RMSE y MAE por sector; pérdida *pinball* y cobertura del intervalo del 80 %, antes y después de calibrar; prueba de Diebold–Mariano frente al AR	Electricidad directa como piso práctico; distintas semillas; calendario de publicación reconstruido; primeras cifras de los últimos 24 meses frente a cifras revisadas; con y sin pandemia
OE2	Ganancia G en los meses de El Niño 2017 y 2023, y en los meses normales	Anomalía semanal Niño 1+2 frente a ICEN rezagado
OE3	Curva de RMSE del mes en curso según el día *d* de información	Con y sin ajuste por feriados
OE4	Si el intervalo contuvo la cifra oficial de agosto y setiembre de 2026; en lo histórico, si las cifras marcadas fueron las más revisadas después	Intervalos del 80 % y del 90 %, con y sin calibración

Durabilidad. El producto descansa en fuentes con acceso estable, un contrato de datos escrito, pruebas automáticas en la ingesta, control de versiones en Git y documentación reproducible, de modo que el INEI pueda operarlo cada mes sin intervención manual.

4. Resultados esperados

Tabla 5. Productos finales y mejora para el INEI

Producto	Contenido	Mejora para el INEI (DTIE)
Nowcast sectorial adelantado	Estimación de la producción nacional y de sus 9 sectores, con intervalo del 80 %, en dos momentos (mes en curso y retroproyección)	Referencia con ~30 días de anticipación en la retroproyección estándar
Informe de exactitud	Tabla de error de la escalera por sector, horizonte y día del mes; pruebas de Diebold–Mariano; resultado de la prueba 9 frente a 52 series	Saber cuánto confiar en la estimación y en qué sectores
Índice diario de actividad	Serie abierta basada en la generación del COES, con ficha metodológica	Primera señal intramensual de actividad en el país
Estudio El Niño	Ganancia de la temperatura del mar en 2017 y 2023; seguimiento del evento 2026–2027	Medición más exacta cuando más se necesita
Señal de control de calidad	Regla que marca cifras fuera del intervalo calibrado, ordenadas por distancia, y validada contra las revisiones posteriores	Revisión focalizada antes del cierre del informe
Tablero y proceso reproducible	Tablero de cuatro paneles, base SQLite, repositorio con tareas programadas e informe académico	Sustituye descargas manuales; historial auditable

Salvaguardas. Toda cifra se rotula como estimación no oficial y se muestra con su intervalo y su fecha de corte; el error histórico del modelo es siempre visible junto a la estimación; y el despliegue es local, sin exponer bases de datos.

5. Limitaciones del Proyecto Integrador

Tabla 6. Limitaciones y estrategias

Tipo	Limitación	Estrategia
Estadística	Muestra mensual corta para redes neuronales y quiebre por la pandemia	Modelo global con 52 series; escalera que convierte la limitación en resultado; indicador de pandemia
Evaluación	Solo dos episodios históricos de El Niño Costero comparables	Se presentan como estudio de caso descriptivo, sin inferencia formal; 2026 añade un tercer caso en tiempo real

Tipo	Limitación	Estrategia
Datos	La temperatura del mar no capta directamente las lluvias en tierra (2017)	Se declara; la precipitación del SENAMHI es la primera extensión
Tiempo real	Solo uno o dos meses de evaluación real dentro de las cinco semanas	Registro con fecha verificable; el sistema queda operando para meses posteriores
Datos	Rezagos de publicación y riesgo de fuga de información	Rezagos según la fecha de estimación, calendario de publicación reconstruido y lista negra verificada antes de cada entrenamiento
Revisiones	El histórico de BCRPData usa cifras ya revisadas, lo que favorece al pseudo tiempo real	Se declara; para los últimos 24 meses se comparan primeras cifras publicadas frente a revisadas
Intervalos	Con muestras cortas, los cuantiles suelen quedar mal calibrados	Calibración conforme y reporte de la cobertura real
Diseño	Nueve sectores del BCRP en lugar de los 14 del INEI	Declarado; los 14 sectores son extensión
Conocimientos	Equipo sin experiencia previa en TFT ni en automatización	Librerías de alto nivel; si el TFT no converge, se reemplaza por N-HiTS (Challu et al., 2023)
Equipo	Cuatro integrantes para cinco semanas	Se retira el LSTM y la extensión de noticias; R4 asume la temperatura del mar, las primeras cifras y el registro mensual para aliviar a R2 y R3
Cómputo	Entrenamiento y ajuste de hiperparámetros	Grilla pequeña definida a priori; GPU gratuita en Colab
Operativa	Automatización de la descarga diaria del COES	Prueba en S1; si falla, se usa la serie mensual y se declara

Extensiones con mayores recursos. (i) **Precipitación diaria del SENAMHI**, primera extensión por las lluvias previstas en la costa norte. (ii) **Noticias como predictor**: indicadores diarios de tono o de menciones de eventos (paros, emergencias) construidos con titulares, como en Kalamara et al. (2022); es el plus sugerido, pero su construcción y validación exceden cinco semanas. (iii) Nowcasting de los 14 sectores del INEI. (iv) Reconciliación jerárquica entre subsectores y sectores.

6. Cronograma (diagrama de Gantt, cinco semanas)

Tabla 7. Roles

Rol	Integrante	Responsabilidad principal
R1 · Ingeniería de datos	Calle Rentería, C. P.	Contrato de datos, calendario de publicación, API del BCRP, COES diario, SQLite, automatización
R2 · Modelos de aprendizaje automático	Ramírez Santos, M. Á.	Formato largo, LightGBM, TFT, prueba 9 frente a 52 series, SHAP y Optuna
R3 · Evaluación, exactitud y módulo El Niño	Shapiama De La Cruz, M.	Referencias con rezago correcto, validación, calibración conforme, curva por día, estudio El Niño 2017–2023 y señal de control
R4 · Tablero, datos oceanográficos y registro	Mendizábal Huanca, L. Á.	Temperatura del mar, fechas ENFEN, datos de pesca, primeras cifras de 24 Informes Técnicos, registro mensual en el repositorio y tablero

Tabla 8. Diagrama de Gantt

Tarea	Rol	S1	S2	S3	S4	S5
Contrato de datos, lista negra y calendario de publicación del INEI	R1	■				
Nowcast de agosto con modelo mínimo (AR + índice eléctrico; plan B: electricidad mensual del BCRP), commit fechado	R3 · R1	■				
Descarga de las 52 series y predictoras; base SQLite con vintages	R1	■	▒			
Descarga diaria del COES e índice diario de actividad	R1	■	▒			
Temperatura del mar (Niño 1+2, ICEN), fechas ENFEN y datos de pesca	R4	■	▒			
Primeras cifras publicadas de los últimos 24 Informes Técnicos	R4		■			
Nowcast de setiembre, versión 1 (~12 de octubre, modelo disponible)	R4 · R3		■			
Formato largo, rezagos según la fecha y ventanas	R2		■			
Referencias (persistencia, electricidad directa y AR) y origen móvil con calendario reconstruido	R3		■			
LightGBM global	R2		▒	■		
TFT global con cuantiles; prueba 9 frente a 52 series	R2			■	■	
Calibración conforme y evaluación: métricas, cobertura y Diebold–Mariano	R3			■	■	
Curva de exactitud según el día del mes	R3 · R1			■	▒	
Estudio El Niño 2017 frente a 2023 (con y sin temperatura del mar)	R3 · R2			■	■	
Nowcast de setiembre, versión 2 (modelo completo) y validación de la señal con las revisiones	R3 · R4				■	▒
Esqueleto del tablero con modelo provisional (hito S2)	R4		■			
Paneles: nowcast, curva de exactitud, El Niño e historial	R4			■	■	
Automatización: actualización diaria y reentrenamiento	R1				■	▒
Integración de punta a punta y pruebas	Todos				▒	■
Informe final, documentación y ensayo de sustentación	Todos				▒	■

Azul oscuro: trabajo principal; azul claro: trabajo parcial o de apoyo. **Hitos: S1, contrato de datos y nowcast de agosto registrado con un modelo mínimo antes de la cifra oficial (si el COES falla, con la electricidad mensual del BCRP)**; S2, flujo completo con un modelo provisional y setiembre versión 1 registrado (condición para avanzar); S3, LightGBM con error medido; S4, TFT calibrado, estudio El Niño y nowcast de setiembre registrado; S5, sistema automatizado, informe y demostración.

7. Respuesta a comentarios

Resumen de los cambios. La versión anterior intentaba hacer demasiadas cosas y ponía en el centro una pregunta que no corresponde al INEI: cuánto responde cada sector a cada shock. Siguiendo la retroalimentación recibida, la propuesta se reorganiza alrededor de una sola idea: **producir un mejor indicador**. El INEI mide; por eso el producto es ahora una estimación temprana de la producción nacional y sectorial, con su exactitud medida y su incertidumbre declarada. Los cambios son cuatro:

- **Nuevo centro: el nowcasting.** El pronóstico del presente con aprendizaje automático para series de tiempo deja de ser el «motor» y pasa a ser el producto. La pregunta ya no es qué relación tiene un shock con un sector, sino cuánta exactitud se gana, cuándo y en qué sectores.

- **Se sacrifican los modelos econométricos.** Se eliminan las proyecciones locales en panel, los errores de Driscoll–Kraay, la corrección de Romano–Wolf, el análisis de potencia, la dependencia del estado y la comparación entre la red y la econometría. Solo se conservan referencias simples (persistencia, electricidad directa y un autorregresivo), porque toda afirmación de exactitud necesita algo contra qué compararse.
- **El Niño entra como información para medir mejor.** La temperatura del mar se incorpora al modelo como variable continua —útil incluso cuando no hay un evento fuerte—; se compara el desempeño en El Niño Costero de 2017 y de 2023, y el sistema se aplica en tiempo real al evento en curso de 2026.
- **Se retira lo que no convergía con el núcleo:** la capa de lenguaje (RAG), el detector Isolation Forest, el shock de conflictividad social y el mapa departamental. Las noticias quedan como extensión opcional, usadas como predictor y no como explicación. El detalle, comentario por comentario, está en la Tabla 9.

Tabla 9. Comentarios recibidos y cómo se atendieron

Comentario	Estado	Cómo se atendió o por qué no	Sección
Centrar el objetivo en el INEI: medición, pronóstico y exactitud; no en qué le importa más a cada sector	Resuelto	Objetivo general reescrito como «mejor indicador»; se elimina la matriz de respuestas sectoriales	1
Mejorar la redacción; «muy difícil de leer»	Resuelto	Metodología en siete pasos numerados, Figura 1, una tabla con cada modelo explicado en una línea y un glosario de términos técnicos (Anexo)	3.2
Comparación con la econometría «ya es mucho»; sacrificar modelos econométricos	Resuelto	Se eliminan proyecciones locales, Driscoll–Kraay, Romano–Wolf, potencia y el OE4 anterior. Se conservan persistencia, electricidad directa y AR solo como referencias de exactitud; el aprendizaje automático se refuerza con Optuna y SHAP	3.2
Le gustó El Niño: comparar con 2017 y hacer nowcasting para ahora	Resuelto	OE2 compara 2017 y 2023; OE4 aplica el sistema en tiempo real al evento 2026	1, 3.2
Usar temperaturas del mar si no hay mucho Niño	Resuelto	Temperatura del mar como variable continua (anomalía semanal Niño 1+2; ICEN solo rezagado)	3.1, 3.2
Noticias de forma predictiva: un plus, pero complejo	Parcial	Se elimina el RAG explicativo; las noticias como predictor quedan como extensión opcional por su costo de construcción	5
«Escalera de modelos ?» y «Ablación ?»	Resuelto	Ambos términos se definen en lenguaje llano; «ablación» pasa a «prueba de 9 frente a 52 series»	3.2
Anotación junto a «~50 series… formato largo»	Resuelto	Lista explícita de las 52 series y criterio de inclusión; se explica la preparación de las series (variación interanual y normalización) y «formato largo» se define en el glosario	3.1, 3.2
Anotación junto a «combinación de pronósticos»	Resuelto	Para simplificar se retiran la combinación de pronósticos, la selección por Lasso y la regresión MIDAS	3.2
Efectos fijos de tiempo, «controles» y shock social	Ya no aplica	Las ecuaciones de panel y el shock social se eliminaron	—
«¿Esto cómo converge con lo anterior?»	Resuelto	Todo alimenta un único nowcast; el índice diario y la temperatura del mar son predictoras, y la señal de control sale del intervalo del mismo modelo	3.2
«Contraste con métricas no es necesario»	Resuelto	Se elimina la evaluación del detector con precisión y exhaustividad; la señal de control no requiere etiquetas	3.2
Reportes con noticias: «¿se busca en noticias si el shock es real? No entendí»	Resuelto	La capa de lenguaje (RAG) se retira del proyecto	—
«Instrumento: ¿cómo?» y «¿es un modelo que sigue corriendo en el tiempo?»	Resuelto	Paso 7 describe el tablero y su ciclo de operación: actualización diaria, registro mensual y reentrenamiento trimestral	3.2
Acceso a cifras preliminares internas del INEI	No resuelto	No tenemos acceso; la señal se prueba con primeras versiones publicadas	3.2

Dudas finales. (1) ¿Sería viable que la DTIE compartiera cifras preliminares o *vintages* internos para probar la señal de control en condiciones reales? (2) ¿Prefiere el profesor mantener el autorregresivo como referencia mínima o reemplazarlo por la persistencia sola? (3) ¿Es adecuado un intervalo del 80 % para el uso institucional, o el INEI preferiría uno del 90 %?

Referencias

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 2623–2631).

Bok, B., Caratelli, D., Giannone, D., Sbordone, A. M., & Tambalotti, A. (2018). Macroeconomic nowcasting and forecasting with big data. *Annual Review of Economics, 10*, 615–643. https://doi.org/10.1146/annurev-economics-080217-053214

Cashin, P., Mohaddes, K., & Raissi, M. (2017). Fair weather or foul? The macroeconomic effects of El Niño. *Journal of International Economics, 106*, 37–54.

Chakraborty, C., & Joseph, A. (2017). *Machine learning at central banks* (Staff Working Paper N.° 674). Bank of England.

Challu, C., Olivares, K. G., Oreshkin, B. N., Garza, F., Mergenthaler-Canseco, M., & Dubrawski, A. (2023). N-HiTS: Neural hierarchical interpolation for time series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence, 37*(6), 6989–6997.

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics, 13*(3), 253–263.

Eurostat. (2017). *European statistics code of practice for the national statistical authorities and Eurostat* (revisado). Comité del Sistema Estadístico Europeo.

Flores, J., Gonzaga, B., Ruelas-Huanca, W., & Tang, J. (2024). *Nowcasting Peruvian GDP with machine learning methods* (Documento de Trabajo N.° 2024-019). Banco Central de Reserva del Perú.

Giannone, D., Reichlin, L., & Small, D. (2008). Nowcasting: The real-time informational content of macroeconomic data. *Journal of Monetary Economics, 55*(4), 665–676.

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735–1780.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Kalamara, E., Turrell, A., Redl, C., Kapetanios, G., & Kapadia, S. (2022). Making text count: Economic forecasting using newspaper text. *Journal of Applied Econometrics, 37*(5), 896–919.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems, 30*, 3146–3154.

Lewis, D. J., Mertens, K., & Stock, J. H. (2022). Measuring real activity using a weekly economic index. *Journal of Applied Econometrics, 37*(4), 667–687.

Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting, 37*(4), 1748–1764.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*, 4765–4774.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting, 36*(1), 54–74.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting, 38*(4), 1346–1364.

Montero-Manso, P., & Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. *International Journal of Forecasting, 37*(4), 1632–1653.

Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems, 32*.

Tenorio, J., & Perez, W. (2024). *GDP nowcasting with machine learning and unstructured data* (Documento de Trabajo N.° 2024-003). Banco Central de Reserva del Perú.

Fuentes de datos

Banco Central de Reserva del Perú. (2026). *BCRPData: Series estadísticas* [Base de datos]. https://estadisticas.bcrp.gob.pe/estadisticas/series/

ENFEN [Comisión Multisectorial encargada del Estudio Nacional del Fenómeno El Niño]. (2026). *Comunicado oficial ENFEN N.° 16-2026: Alerta de El Niño Costero* (14 de setiembre). https://enfen.imarpe.gob.pe/download/comunicado-oficial-enfen-n-16-2026/

Comité de Operación Económica del Sistema Interconectado Nacional. (2026). *Generación y demanda diaria del SEIN* [Conjunto de datos]. https://www.coes.org.pe/Portal/portalinformacion/generacion

Instituto Geofísico del Perú & ENFEN. (2026). *Índice Costero El Niño (ICEN), serie mensual 1950–2026* [Conjunto de datos]. http://met.igp.gob.pe/datos/ICEN.txt

NOAA Climate Prediction Center. (2026). *Weekly OISST anomalies, Niño regions* [Conjunto de datos]. https://www.cpc.ncep.noaa.gov/data/indices/

Anexo. Glosario de términos técnicos

Definiciones breves, en el sentido en que se usan en esta propuesta.

Término	Significado
Anomalía de temperatura del mar	Diferencia entre la temperatura superficial del mar observada y su valor normal para esa época del año. Una anomalía positiva indica un mar más cálido de lo habitual.
API	Interfaz que permite descargar datos de una institución (por ejemplo, el BCRP) directamente con un programa, sin entrar a la página web.
Aprendizaje automático (machine learning)	Conjunto de métodos en que el computador aprende patrones a partir de datos históricos, en lugar de seguir una fórmula fijada de antemano.
Autorregresivo (AR)	Modelo estadístico simple que estima el valor de una serie como combinación lineal de sus valores pasados. Se usa como referencia.
Calibración conforme	Ajuste del ancho del intervalo, usando datos no vistos en el entrenamiento, para que su cobertura real se acerque a la nominal (aquí, 80 %).
Cobertura del intervalo	Porcentaje de meses en que la cifra oficial cayó dentro del intervalo estimado. Un intervalo del 80 % bien calibrado debería contenerla en 8 de cada 10 meses.
COES y SEIN	Comité de Operación Económica del Sistema y Sistema Eléctrico Interconectado Nacional; el COES publica la generación eléctrica diaria del SEIN.
Commit	Registro fechado de un cambio en el repositorio de código (Git). Prueba en qué fecha se guardó cada nowcast.
Cuantil	Valor por debajo del cual se espera una proporción dada de resultados. El cuantil 0,1 deja el 10 % por debajo; el 0,9, el 90 %.
Diebold–Mariano (prueba de)	Prueba estadística que indica si la diferencia de error entre dos modelos de pronóstico es significativa o puede deberse al azar.
Dropout	Técnica que, durante el entrenamiento de una red neuronal, apaga al azar algunas neuronas para evitar que memorice los datos.
DTIE	Dirección Técnica de Indicadores Económicos del INEI, que elabora el Avance Coyuntural y el Informe Técnico de Producción Nacional.
Early stopping	Detener el entrenamiento cuando el error en datos de validación deja de bajar, para evitar el sobreajuste.
El Niño Costero	Calentamiento anómalo del mar frente a la costa peruana (región Niño 1+2). El ENFEN declara su inicio, fin y magnitud.
Electricidad directa	Referencia ingenua que toma la variación interanual de la electricidad como estimación de la producción, sin estimar ningún modelo.
Formato largo	Tabla con una fila por serie y mes; el nombre de la serie es una columna más que el modelo puede usar.
Fuga de información	Error que ocurre cuando el modelo usa, sin querer, datos que no estarían disponibles en el momento de estimar. Produce errores artificialmente bajos.
Hiperparámetro	Ajuste de un modelo que se fija antes de entrenarlo (por ejemplo, el número de capas de una red), a diferencia de los parámetros que el modelo aprende.
ICEN	Índice Costero El Niño: promedio móvil de tres meses de la anomalía de temperatura del mar en la región Niño 1+2, calculado por el IGP para el ENFEN; su valor más reciente es provisional.
IGV interno	Impuesto General a las Ventas recaudado por operaciones internas; aproxima el consumo. La recaudación de un mes refleja las ventas del mes anterior.
Intervalo de predicción	Rango dentro del cual se espera que esté la cifra real con una probabilidad dada (aquí, 80 %). Expresa la incertidumbre de la estimación.
LightGBM	Método de aprendizaje automático basado en muchos árboles de decisión pequeños que se corrigen unos a otros. Es rápido y funciona bien con datos tabulares.
MAE y RMSE	Medidas del error promedio de un pronóstico. El MAE promedia los errores absolutos; el RMSE penaliza más los errores grandes.
Modelo global	Un único modelo que aprende de muchas series a la vez (aquí, 52), en lugar de estimar un modelo distinto para cada serie.
Niño 1+2 (región)	Zona del océano Pacífico frente a la costa de Perú y Ecuador cuya temperatura se usa para medir El Niño Costero.
Normalización	Transformación que pone todas las series en una escala comparable, restando su media y dividiendo entre su desviación estándar.

Término	Significado
Nowcast (nowcasting)	Estimación del valor de un mes que ya ocurrió o está ocurriendo, pero cuya cifra oficial aún no se publica. No es un pronóstico del futuro.
Optuna	Programa que busca de forma automática la mejor combinación de hiperparámetros de un modelo.
Origen móvil (validación de)	Forma de evaluar pronósticos que respeta el orden del tiempo: el modelo se entrena con datos hasta una fecha y se evalúa en el mes siguiente, avanzando mes a mes.
Pérdida pinball	Medida de error usada para entrenar y evaluar cuantiles; castiga de forma distinta las estimaciones que quedan por encima y por debajo de la cifra real.
Persistencia	Referencia más simple posible: suponer que la variación del mes será igual a la última cifra oficial publicada.
Predictora	Variable que el modelo usa para estimar la cifra de interés (por ejemplo, la electricidad para estimar el PBI).
Primera cifra publicada	Valor que el INEI difundió por primera vez para un mes, antes de revisiones posteriores.
Reentrenamiento	Volver a estimar el modelo con los datos más recientes para que no pierda exactitud con el tiempo.
Retroproyección	Estimación de un mes ya cerrado cuya cifra oficial aún no se publica; dispone de más información que la estimación del mes en curso.
Rezago de publicación	Tiempo entre el fin del mes y la difusión de su cifra. Determina qué datos existen el día en que se estima.
Señal de control de calidad	Alerta automática que se activa cuando una cifra cae fuera del intervalo del modelo, para revisarla antes de publicar.
SHAP	Método que muestra cuánto contribuyó cada variable a una estimación concreta de un modelo de aprendizaje automático.
SQLite	Base de datos ligera guardada en un solo archivo, que no requiere instalar un servidor.
Streamlit	Herramienta de Python para construir tableros web interactivos con poco código.
TFT (Temporal Fusion Transformer)	Red neuronal para series de tiempo que combina memoria y atención, entrega intervalos y muestra qué variables pesaron en cada estimación.
Variación interanual	Cambio porcentual de una cifra respecto del mismo mes del año anterior; elimina el efecto de la estacionalidad.
Vintage	Copia de los datos tal como estaban disponibles en una fecha dada, para evaluar el modelo sin usar información que entonces no existía.

Cómo? Fórmula.

- Este glosario es útil pero no tiene definiciones self-contained
- No me dice qué son exactamente