Las emergencias que alimentan el modelo

Qué es DesInventar, por qué termina en 2015 y cómo cubre el proyecto el periodo 2016-2026

Proyecto integrador del Programa de Extensión Universitaria: Ciencia del Dato (PEU-CD), INEI 2026
Equipo: Marcia, Christopher, Maykol y Luz Ángela
Repositorio analizado: github.com/MarciaShapiama/iapn-inei · Tablero: marciashapiama.github.io/iapn-inei

La respuesta corta

1. DesInventar tiene emergencias con fecha solo hasta noviembre de 2015. Con esa data se entrena el **modelo de alerta**.

2. Para 2016-2026 ese modelo **no necesita la variable Y**: calcula el riesgo de cada semana con lluvia, caudal y mar, que sí están al día. Pero tampoco tiene una Y real para medir sus aciertos en esos años.

3. Para cubrir el periodo reciente, el proyecto usa otra fuente oficial: el **SINPAD del INDECI**, publicado en datos abiertos de 2003 a 2026. Con ella se entrena un **segundo modelo** (viviendas afectadas) y se comprueba el aviso de lluvia.

4. Las dos fuentes no coinciden: SINPAD registra muchas más emergencias que DesInventar en los mismos años. Hay que entender esa diferencia antes de unirlas.

Este documento describe lo que hace el código del repositorio al 5 de noviembre de 2026 (src/base_modelo.py, src/modelo_inundacion.py y src/modelo_afectados.py) y cifras calculadas con sus archivos de datos.

Contenido

Parte	Pregunta que responde
1	¿Qué es DesInventar y cómo se recolecta su información?
2	¿Cómo se convierte DesInventar en la variable Y del modelo?
3	¿Por qué hay un vacío desde 2016?
4	Solución 1: ¿cómo trabaja el modelo de alerta sin Y después de 2015?
5	Solución 2: ¿cómo se usa el SINPAD del INDECI? (8 pasos)
6	¿Qué otras fuentes cubren el periodo reciente?
7	¿Coinciden DesInventar y SINPAD?
8	¿Cómo explicarlo al profesor? Guion y preguntas probables
9	Limitaciones, lo que no se verificó y próximos pasos

1. Qué es DesInventar y cómo se recolecta

DesInventar es una base de datos de desastres impulsada por la Oficina de las Naciones Unidas para la Reducción del Riesgo de Desastres (UNDRR). Cada fila es **un evento**: qué pasó (inundación, lluvias, huaico, incendio, sismo…), **en qué fecha**, **en qué distrito** y qué daños dejó (muertos, afectados, damnificados, viviendas destruidas o afectadas).

De dónde vienen sus registros. Para el Perú recoge principalmente los reportes de emergencia del INDECI, que a su vez provienen de las oficinas de Defensa Civil de los gobiernos locales y regionales y del Centro de Operaciones de Emergencia Nacional (COEN). En años antiguos también incorpora prensa escrita (hemeroteca) y otros archivos institucionales.

Cómo la obtiene el proyecto. El script `src/base_modelo.py` descarga la exportación pública para el Perú (`desinventar.net/DesInventar/download/DI_export_per.zip`) y se queda con los registros de Tumbes y Piura.

Dato	Valor en el archivo del proyecto
Registros de Tumbes y Piura (todos los tipos)	1 983, de 1970 a 2015
Tipos más frecuentes	Lluvias 525 · Inundación 410 · Epidemia 196 · Sequía 100 · Marejada 94 · Incendio 87
¿Tienen fecha completa?	Sí: en los registros de agua revisados desde 2001, todos tienen día, mes y año
Última fecha disponible	Noviembre de 2015

De todos esos tipos, el modelo usa solo los relacionados con agua, desde abril de 2001 (según la guía didáctica del equipo):

Tipo de evento	Registros	¿Depende de la lluvia?
Inundación	92	Sí
Lluvias	54	Sí
Marejada	29	**No**: es oleaje del mar
Aluvión (huaico)	8	Sí
Avenida torrencial	3	Sí
Total	**186**	

¿Es una serie diaria? No exactamente. Cada registro tiene su **fecha exacta**, pero DesInventar es una **lista de eventos**: los días en que no pasó nada no aparecen. El proyecto convierte esa lista en una serie **semanal por distrito**.

2. De DesInventar a la variable Y

La variable Y es lo que el modelo de alerta quiere predecir. En el código se llama `emergencia_1a4`. Se construye en dos pasos.

Paso A: la variable auxiliar E (lo que pasó esa semana)

Para cada distrito *d* y cada semana *t* (de lunes a domingo):

`E(d, t) = 1 si hay al menos un registro de agua en el distrito d durante la semana t; si no, 0`

Paso B: la variable Y (lo que pasará en el próximo mes)

`Y(d, t) = 1 si E(d, t+1) + E(d, t+2) + E(d, t+3) + E(d, t+4) ≥ 1; Y(d, t) = 0 en otro caso`

Las dos son **semanales**: hay un valor por distrito y semana. E mira **la semana actual**; Y mira **las 4 semanas siguientes**. E es el ingrediente con el que se fabrica Y.

Ejemplo real: Zarumilla, 2002

En DesInventar, Zarumilla tiene dos registros de agua en ese periodo: **lluvias el 4 de marzo** y **marejada el 19 de marzo** (además de una ola de calor el 24 de febrero, que no cuenta porque no es un evento de agua).

Semana	E	E de las 4 semanas siguientes	Y
28 ene	0	0 · 0 · 0 · 0	0
04 feb	0	0 · 0 · 0 · **1**	**1**
11 feb	0	0 · 0 · **1** · 0	**1**
18 feb	0	0 · **1** · 0 · **1**	**1**
25 feb	0	**1** · 0 · **1** · 0	**1**
04 mar	**1**	0 · **1** · 0 · 0	**1**
11 mar	0	**1** · 0 · 0 · 0	**1**
18 mar	**1**	0 · 0 · 0 · 0	0
25 mar	0	0 · 0 · 0 · 0	0

Tres cosas que muestra el ejemplo: (1) un registro «enciende» las 4 semanas anteriores; (2) la semana del propio registro puede valer 0, porque Y mira solo hacia adelante; (3) seis semanas con Y = 1 vienen de solo dos registros, y uno de ellos es una marejada, que no depende de la lluvia.

Lo que significa Y = 0. Y no es un estado («el distrito está inundado»); es la **aparición de un registro nuevo**. Vale 0 cuando en las 4 semanas siguientes no aparece ningún registro. Por eso no hace falta saber cuándo termina una emergencia ni cuándo el COEN la levanta. Si no se reportó nada, se asume que no hubo emergencia (puede haber subregistro).

Cifras de Y con la base del proyecto

Indicador	Valor
Semanas-distrito con Y calculada (abril 2001 a octubre 2015)	57 836
Con Y = 1	651 (1,13 %)
En el periodo de prueba 2008-2015	311 de 31 008 (1,0 %), que son unos 73 eventos distintos
Eventos que aparecen en una sola semana	97,7 %
Distritos con al menos un Y = 1	47 de 75

3. Por qué hay un vacío desde 2016

La exportación de DesInventar que descarga el proyecto **no trae registros fechados de Tumbes y Piura después de noviembre de 2015**. No es una decisión del equipo: es lo que contiene la fuente.

Esto afecta solo a la **variable Y**. Las variables que describen las condiciones de cada semana (lluvia de NASA POWER, caudal de GloFAS, temperatura del mar de NOAA) **sí están completas hasta hoy**.

Periodo	Condiciones (X): lluvia, caudal, mar	Emergencias (Y) de DesInventar
2001-2015	Sí	Sí
2016-2026	Sí, actualizadas cada semana	**No**

El proyecto responde a ese vacío con **dos soluciones distintas**, una para cada modelo. Es importante no mezclarlas al explicarlas.

4. Solución 1: el modelo de alerta no necesita Y después de 2015

Un modelo necesita la Y para **aprender**, pero no para **predecir**. Funciona como estudiar con exámenes antiguos que traen las respuestas: se usan para aprender y después se responde un examen nuevo sin la hoja de respuestas.

Etapa	Años	Qué se usa	Resultado
Aprender (entrenar)	2001-2015	X y la Y de DesInventar	Pesos del modelo: cuánto sube el riesgo con más lluvia, más caudal, mar más caliente, historia del distrito y época del año
Medir aciertos	2008-2015, año por año	Se entrena con los años anteriores y se prueba en cada año	PR-AUC, ROC-AUC y captura (documentados por el equipo)
Predecir	2016-hoy	Solo X	Riesgo semanal por distrito (riesgo_2016_hoy.csv), el que muestra el tablero

Cómo se revisa después de 2015 sin Y. Se compara el riesgo medio de enero a abril de cada año. Sin haberlos visto en el entrenamiento, el modelo pone **2017 en el puesto 1 y 2023 en el puesto 2** de 11 años. Es una señal de que tiene sentido, pero es un ranking de años, no una medida de aciertos semana a semana.

> **Lo que esta solución no resuelve.** El modelo de alerta **nunca aprendió de El Niño 2017 ni del ciclón Yaku 2023**, los eventos más importantes para el proyecto, y no se pueden medir sus aciertos semanales después de 2015.

5. Solución 2: el SINPAD del INDECI (2003-2026)

Para responder lo que pidió el profesor en la reunión del 4 de noviembre (predecir cuántas viviendas pueden verse afectadas y dónde), el equipo armó un segundo modelo, `src/modelo_afectados.py`, con una fuente que sí cubre los años recientes: el **SINPAD** (Sistema de Información Nacional para la Respuesta y Rehabilitación) del INDECI, publicado en la Plataforma Nacional de Datos Abiertos. El código lo procesa en ocho pasos.

1 Descargar los archivos oficiales

Qué hace: Baja dos archivos CSV públicos del INDECI («Emergencias y daños a nivel nacional», licencia ODC-By) desde datosabiertos.gob.pe: `BD_2003-2025_EMERGENCIAS.csv` y `BD_2026_Semestre_I.csv`.

Por qué: Es la fuente oficial de emergencias del Estado con fecha y distrito, y se actualiza hasta 2026.

2 Quedarse con Tumbes y Piura

Qué hace: Conserva solo los registros cuyo UBIGEO empieza con 20 (Piura) o 24 (Tumbes).

Por qué: El proyecto es un piloto en esos dos departamentos.

3 Quedarse con los peligros de agua

Qué hace: Conserva solo los registros cuyo peligro contiene «INUNDACIÓN» o «LLUVIA» (inundación y lluvia intensa).

Por qué: Son los peligros que se relacionan con El Niño y con las variables del modelo. Así se evita, por ejemplo, el problema de las marejadas de DesInventar.

4 Corregir las fechas

Qué hace: El archivo mezcla formatos: de 2003 a 2024 la fecha viene como día/mes/año y en 2025-2026 como mes/día/año. El código usa la columna «MES» para decidir cuál número es el día y cuál el mes.

Por qué: Sin esta corrección, el 3 de abril podría leerse como 4 de marzo y caer en otra semana.

5 Descartar un error de la fuente

Qué hace: En el archivo de 2026, en 132 de 302 registros, la columna de viviendas destruidas repite el número de personas afectadas. Ese dato de 2026 se pone en 0.

Por qué: Contar personas como viviendas inflaría el resultado del modelo de viviendas.

6 Unir los distritos nuevos

Qué hace: Veintiséis de Octubre se suma a Piura y Canoas de Punta Sal a Zorritos.

Por qué: El mapa de distritos que usa el proyecto (GADM) no los tiene por separado; se comprobó que sus territorios caen dentro de esos distritos.

7 Agrupar por distrito y semana

Qué hace: Cada registro se asigna a su semana (de lunes a domingo) y se suman, por distrito y semana, los eventos, los de inundación, las viviendas afectadas y destruidas, los afectados y los damnificados. El resultado es `data/modelo/sinpad_tumbes_piura_semanal.csv`.

Por qué: Tiene la misma unidad que el resto del proyecto (distrito-semana) y se puede unir con las variables de lluvia, caudal y mar.

8 Definir hasta dónde confiar y cómo probar

Qué hace: La etiqueta se usa hasta el 29 de diciembre de 2025 y el modelo se prueba en los años 2012 a 2025.

Por qué: El archivo de 2026 tiene el problema del paso 5, y probar en años recientes mide cómo funcionaría hoy.

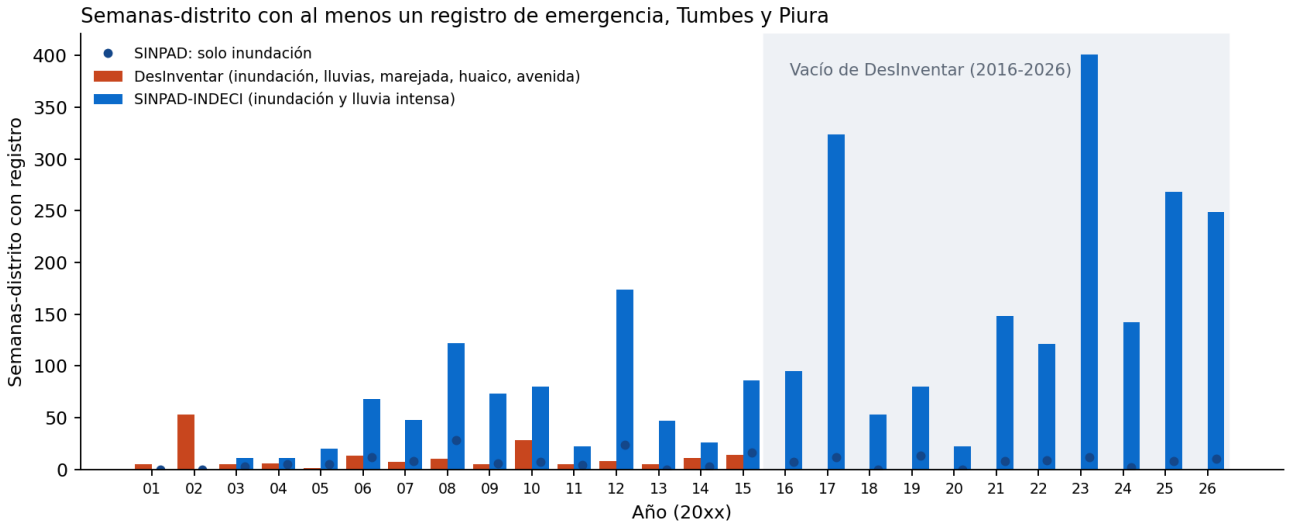
El archivo semanal resultante tiene 2 691 semanas-distrito con al menos un registro, en los 78 distritos, del 27 de enero de 2003 al 29 de junio de 2026.

6. Otras fuentes que cubren el periodo reciente

Fuente	Qué trae	Para qué se usa	Límite
Tablas estadísticas del INDECI 2003-2024 (gob.pe)	Afectados y damnificados por distrito y tipo de peligro	Validar **dónde** hay más daños: ¿los distritos con más exposición son los que más afectados tuvieron?	Sin fecha: no sirve para saber **cuándo**
SINPAD semanal (el mismo de la parte 5)	Emergencias por distrito y semana 2003-2026	Comprobar si el aviso de lluvia y caudal coincide con semanas con daños	Depende del reporte de cada municipalidad
Noticias (Google Noticias y catálogo verificado)	Inundaciones de 2025-2026 con lugar y fecha	Probar si el aviso habría anticipado eventos recientes y mostrarlos en el mapa	No son registros oficiales
Mapa oficial de Copernicus (EMSR199)	Zonas inundadas en Piura en 2017	Validar el radar	Solo cubre 2017

7. ¿Coinciden DesInventar y SINPAD?

Se contaron las semanas-distrito con al menos un registro en cada fuente. DesInventar incluye inundación, lluvias, marejada, huaico y avenida; el SINPAD del proyecto, inundación y lluvia intensa.



Años 2003-2015	Semanas-distrito con registro
DesInventar (tipos de agua)	118
SINPAD: inundación y lluvia intensa	788 (unas 6,7 veces más)
SINPAD: solo inundación	121

Cómo leerlo:

• **SINPAD registra muchas más emergencias que DesInventar** en los mismos años, sobre todo por lluvia intensa. La mayor parte del SINPAD no es «inundación» sino «lluvia intensa».

• **Los años altos no coinciden.** En DesInventar destacan 2002 y 2010; en SINPAD, 2008 y 2012. En 2010 DesInventar tiene 28 semanas-distrito y SINPAD 80; en 2012, 8 y 174.

• **Después de 2015 solo existe SINPAD**, y muestra claramente los años de El Niño y Yaku: 2017 (324) y 2023 (401). 2026 llega solo hasta junio.

Conclusión. No se puede pegar SINPAD a continuación de DesInventar como si fueran la misma serie: cambiaría lo que significa Y = 1 de un año a otro. Para extender la Y del modelo de alerta hasta 2026 conviene **usar una sola fuente para todo el periodo** (por ejemplo, SINPAD 2003-2025) y volver a entrenar y evaluar.

8. Cómo explicarlo al profesor

Guion sugerido (un minuto)

«Nuestra variable dependiente sale de DesInventar, que recoge los reportes de emergencia del INDECI y de Defensa Civil, y en años antiguos también de prensa. Tiene fecha y distrito, pero solo hasta 2015. Con ella construimos Y por semana: vale 1 si en las 4 semanas siguientes se registra una emergencia por inundación o lluvias en el distrito, y 0 si no.»

«Con 2001-2015 entrenamos el modelo de alerta. Para 2016 en adelante el modelo calcula el riesgo semanal con lluvia, caudal y mar, que sí están al día, pero no tenemos una Y para medir sus aciertos semana a semana. Lo revisamos con el ranking de años: sin haberlos visto, pone 2017 y 2023 en los dos primeros lugares.»

«Para el periodo reciente usamos el SINPAD del INDECI, publicado en datos abiertos de 2003 a 2026. Lo filtramos por Tumbes y Piura y por inundación y lluvia intensa, corregimos las fechas y lo agrupamos por distrito y semana. Con él entrenamos el modelo de viviendas afectadas. No lo unimos a DesInventar porque registra muchas más emergencias y en años distintos.»

Preguntas probables y cómo responderlas

Pregunta	Respuesta
¿Por qué no usan SINPAD para todo el modelo de alerta?	Es el siguiente paso. Antes hay que entender por qué SINPAD registra unas 6,7 veces más semanas con emergencia que DesInventar en los mismos años; si se mezclan, Y = 1 significaría cosas distintas según el año.
¿Existe una Y para 2016-2026?	En el modelo de alerta, no. En el modelo de viviendas afectadas sí, con SINPAD hasta diciembre de 2025.
¿Cómo saben que el modelo funciona después de 2015?	De forma indirecta: ordena 2017 y 2023 como los años más riesgosos. Y el aviso de lluvia y caudal se comprobó con SINPAD y con noticias.
¿Por qué semanas y no días?	Los registros diarios tienen mucho ruido (una emergencia se reporta un día u otro) y un aviso con una o más semanas de anticipación es más útil.
¿Qué pasa si una emergencia no se reportó?	Ese distrito queda con Y = 0. Es un supuesto: puede haber subregistro, sobre todo en distritos pequeños.
¿Por qué hay marejadas en Y?	Es un error de diseño que ya identificamos: son oleaje del mar, no lluvia (29 de 186 registros). Recomendamos sacarlas y volver a entrenar.
¿Cuántos casos reales tienen?	En 2008-2015 hay 311 semanas con Y = 1, pero corresponden a unos 73 eventos distintos, porque cada evento llena 4 semanas.

9. Limitaciones, lo que no se verificó y próximos pasos

Limitaciones

• DesInventar termina en 2015: el modelo de alerta no aprendió de 2017 ni de 2023.

• Y marca la aparición de un registro, no la duración de la emergencia (el 97,7 % de los eventos aparece en una sola semana).

• Las marejadas de DesInventar están dentro de Y y no dependen de la lluvia.

• Ambas fuentes dependen de lo que reporta cada municipalidad (posible subregistro) y la fecha es la del registro, no siempre la del evento.

• DesInventar y SINPAD no coinciden en cantidad ni en los años con más registros.

Lo que no se verificó en este documento

• Que los archivos de datos abiertos del INDECI sigan disponibles en esas direcciones.

• Los resultados del modelo de viviendas afectadas: aquí solo se describe cómo se arma su etiqueta.

• La causa de las diferencias entre DesInventar y SINPAD (criterios de registro, cobertura o cambios en el sistema).

Próximos pasos sugeridos

Paso	Para qué
1. Sacar las marejadas de Y y volver a entrenar	Que Y solo contenga eventos que dependen de la lluvia
2. Comparar DesInventar y SINPAD evento por evento en 2003-2015	Entender por qué difieren antes de elegir una sola fuente
3. Construir Y con SINPAD 2003-2025 para el modelo de alerta	Incluir 2017 y 2023 en el entrenamiento y medir aciertos recientes
4. Mostrar al profesor la distribución de Y por año, mes y distrito	Es lo que pidió en la reunión del 5 de noviembre

Glosario

Término	Significado
DesInventar	Base de datos de desastres de la ONU (UNDRR) que recoge registros del INDECI y, en años antiguos, de prensa.
SINPAD	Sistema de información del INDECI donde se registran las emergencias y sus daños.
COEN	Centro de Operaciones de Emergencia Nacional, del INDECI.
Variable dependiente (Y)	Lo que el modelo quiere predecir: si habrá una emergencia en las próximas 4 semanas.
Variable auxiliar (E)	Si hubo un registro de emergencia en la semana actual. Con ella se construye Y.
Semana-distrito	Una fila de la base: un distrito en una semana de lunes a domingo.
Entrenar / predecir	Entrenar es aprender con datos que tienen Y; predecir es aplicar lo aprendido a semanas sin Y.
UBIGEO	Código oficial que identifica a cada distrito del Perú.