PROYECTO INTEGRADOR · PEU-CD INEI

Inundaciones por El Niño en Tumbes y Piura

Avance: fuentes, modelo de predicción y límites de las imágenes satelitales

Marcia · Christopher · Maykol · Luz Ángela — Noviembre 2026

FUENTES DE DATOS

Todo sale de fuentes abiertas, oficiales o citables

Tema	Fuente	Detalle	Para qué la usamos
Peligro	JRC CEMS-GloFAS v2	90 m · 1 en 10 y 1 en 100 años	Zona inundable por río
Radar	Copernicus Sentinel-1	Pasa cada 6 a 12 días	Agua detectada en 2017, 2023 y hoy
Fotos	Copernicus Sentinel-2	Óptico: lo tapan las nubes	Comparador antes y después
Población	WorldPop 2026	Modelada, en malla	Personas expuestas
Edificaciones	Google Open Buildings v3	Huella de cada edificio	Estructuras expuestas
Servicios	ESCALE (MINEDU), RENIPRESS	Un punto por local	Colegios y salud expuestos
Lluvia	NASA POWER, Open-Meteo	Diaria desde 2001 · ~50 km	Variable del modelo
Ríos	GloFAS v4	Caudal diario modelado	Variable del modelo
Mar	NOAA OISST, CPC, IGP	Niño 1+2, Niño 3.4, ICEN	Variable del modelo
Emergencias	DesInventar / INDECI	Con fecha 2001–2015	Variable dependiente

Licencias y fecha de cada capa: dashboard/data/metadatos.json · 2

PLANTEAMIENTO · VARIABLE DEPENDIENTE (Y)

Qué queremos predecir, en fórmula

EMERGENCIA_1A4

Y(d, t) = 1 si E(d, t+1) + E(d, t+2) + E(d, t+3) + E(d, t+4) ≥ 1

Y(d, t) = 0 en otro caso

d = distrito · t = semana (lunes a domingo) · E(d, t) = 1 si DesInventar registra una inundación, lluvia, desborde o avenida en el distrito d durante la semana t.

Sujeto a

Y solo toma 0 o 1. Solo hay Y donde la emergencia tiene fecha (abril 2001 a 2015). Las 4 últimas semanas con dato quedan sin Y: aún no se sabe.

Tipo de problema

Clasificación binaria supervisada. El modelo no responde sí o no: estima P(Y = 1 | X), un número entre 0 y 1.

Casos raros

En 2008–2015, solo 311 de 31 008 distrito-semanas tienen Y = 1 (1 %). Un modelo que diga siempre «no» acertaría 99 % y no serviría.

Fuente: DesInventar (registro de INDECI), 75 distritos · construcción: src/base_modelo.py · 3

VARIABLES INDEPENDIENTES (X) · PARTE 1 DE 2 · CAMBIAN CADA SEMANA

Lluvia, ríos y mar

Variable	Qué significa	Unidad	Fuente
lluvia_7d	Lluvia acumulada en la semana	mm	NASA POWER
lluvia_30d	Lluvia acumulada en las últimas 4 semanas	mm	NASA POWER
lluvia_90d	Lluvia acumulada en las últimas 13 semanas	mm	NASA POWER
lluvia_*_anom	Cada lluvia menos su promedio 2001–2020 en esa semana	mm	NASA POWER
lluvia_7d_prev	Lluvia de la semana anterior	mm	NASA POWER
caudal	Caudal del río más cercano: Tumbes, Chira o Piura	m^3/s	GloFAS v4
caudal_razon	Caudal ÷ su mediana 2001–2020 (1 = normal, 3 = triple)	veces	GloFAS v4
caudal_max_4s	Caudal más alto de las últimas 4 semanas	m^3/s	GloFAS v4
nino12	Anomalía del mar frente a Perú y Ecuador (Niño 1+2)	°C	NOAA CPC
nino34	Anomalía del mar en el Pacífico central (Niño 3.4)	°C	NOAA CPC

NASA POWER: punto central del distrito, celdas de ~50 km · GloFAS v4 vía Open-Meteo · NOAA CPC semanal · 4

VARIABLES INDEPENDIENTES (X) · PARTE 2 DE 2 · DESCRIBEN AL DISTRITO

Exposición, historia y época del año

Variable	Qué significa	Unidad	Fuente
km2_inundable_rp10	Área del distrito inundable en un evento de 1 en 10 años	km^2	JRC
km2_inundable_rp100	Lo mismo para un evento de 1 en 100 años	km^2	JRC
viviendas_rp10, rp100	Edificaciones dentro de esa zona inundable	número	Open Buildings
personas_rp100	Personas dentro de la zona de 1 en 100 años	personas	WorldPop
frecuencia_historica	Proporción de semanas con emergencia del distrito, solo en los años de entrenamiento	0 a 1	DesInventar
sen_semana	$\text{sen}(2\pi \cdot s \div 52)$, con s = semana del año (1 a 52)	−1 a 1	Calendario
cos_semana	$\cos(2\pi \cdot s \div 52)$	−1 a 1	Calendario

¿Por qué seno y coseno? El año es circular: la semana 52 y la 1 están juntas. Con esas dos coordenadas el modelo reconoce la temporada de lluvias (enero a abril) sin un corte en Año Nuevo.

MODELO PRINCIPAL · REGRESIÓN LOGÍSTICA SIMPLE (6 VARIABLES)

La fórmula del modelo

$$P(Y = 1 \mid X) = 1 \div (1 + e^{(-\eta)})$$

$$\eta = \beta_0 + \beta_1 \cdot \log(1 + \text{lluvia_30d}) + \beta_2 \cdot \log(\text{caudal_razon}) + \beta_3 \cdot \text{nino12} + \beta_4 \cdot \text{frecuencia_historica} + \beta_5 \cdot \text{sen_semana} + \beta_6 \cdot \text{cos_semana}$$

P(Y = 1 | X)

Probabilidad de emergencia en las próximas 4 semanas, dados los valores de X.

η (eta)

Puntaje lineal. La función logística lo convierte en un número entre 0 y 1.

β0 … β6

Pesos que el modelo aprende. Si β > 0, esa variable sube el riesgo.

log( )

Suaviza los valores extremos. El +1 evita log(0); la razón de caudal se acota en 0,05.

log = logaritmo natural · e ≈ 2,718 · código: src/modelo_inundacion.py (lista SIMPLE) · 6

SUJETO A · CÓMO SE ESTIMAN LOS B

Cómo aprende el modelo y qué pesos encontró

1. Función objetivo

$\min \frac{1}{2} \|\beta\|^2 + C \cdot \Sigma\, w_i \cdot \ell(y_i, p_i)$, con C = 0,3. ℓ es la pérdida logarítmica; el primer término (L2) castiga los β grandes.

2. Pesos balanceados

$w_i = n \div (2 \cdot n$ de su clase). Una semana con emergencia pesa como unas 100 semanas sin emergencia.

3. Estandarización

Cada X pasa a z = (x − media) ÷ desviación estándar del entrenamiento. Así los β se pueden comparar.

4. Datos faltantes

Se reemplazan por la mediana del entrenamiento.

Variable	β (estand.)
log lluvia 30 días	+0,024
log razón de caudal	+0,069
Niño 1+2	+0,039
Frecuencia histórica	+1,191
Seno de la semana	+0,863
Coseno de la semana	+0,843

Todos los signos son positivos, como se esperaba. Pero la historia y la época pesan de 12 a 50 veces más que la lluvia o el caudal.

MODELOS TENTATIVOS · LOS MISMOS DATOS Y LAS MISMAS REGLAS

Contra qué comparamos el modelo principal

Climatología · referencia

p = ½ · tasa(distrito, mes) + ½ · tasa(mes)

tasa = proporción de semanas con Y = 1 en el entrenamiento, por bloques de 4 semanas. No usa clima. Si un modelo no le gana, no aporta.

Logística completa

Misma fórmula, con las 20 variables

Mismas reglas de estimación. Problema: las lluvias de 7, 30 y 90 días se parecen mucho y algunos β salen negativos. No reconoce 2017.

LightGBM

p = suma de 200 árboles pequeños

Profundidad 2, aprendizaje 0,03, al menos 400 casos por hoja, λ = 10. Restricción: más lluvia o caudal nunca baja el riesgo. Con 311 positivos se sobreajusta.

Parámetros exactos: src/modelo_inundacion.py (funciones climatologia, logistica, lightgbm) · 8

CÓMO PREDECIMOS Y CÓMO LO MEDIMOS

Validación año por año, sin mirar el futuro



Azul = años para entrenar · naranja = año de prueba. Se quitan las 4 últimas semanas del entrenamiento, porque su Y mira dentro del año de prueba.

Del modelo al tablero

riesgo = 100 × proporción de distrito-semanas 2001–2015 con probabilidad menor

Alerta interna si riesgo ≥ 95: el 5 % más alto de la historia. No se muestra como %, porque la probabilidad no está calibrada.

PR-AUC
Precisión frente a exhaustividad. Al azar: 0,010.

ROC-AUC
Prob. de ordenar bien un sí frente a un no. Al azar: 0,5.

Brier
Promedio de $(p - y)^2$. Menor es mejor.

Captura 5 %
% de emergencias en el 5 % más riesgoso.

¿ESTÁ PREDICIENDO? · RESULTADOS 2008–2015

Todavía no sirve como alerta, pero sí ordena años y distritos

Modelo	PR-AUC	ROC-AUC	Captura
Climatología	0,095	0,829	37 %
Logística simple	0,114	0,865	30 %
Logística completa	0,122	0,846	36 %
LightGBM	0,082	0,811	33 %

Un modelo al azar tendría PR-AUC de 0,010. Captura = % de emergencias en el 5 % de semanas más riesgosas.

No predice la semana: le gana a la climatología con 92 % de probabilidad, pero el intervalo incluye el cero.

Sí reconoce El Niño: sin haberlos visto, pone 2017 en el puesto 1 y 2023 en el 2 de 11 años.

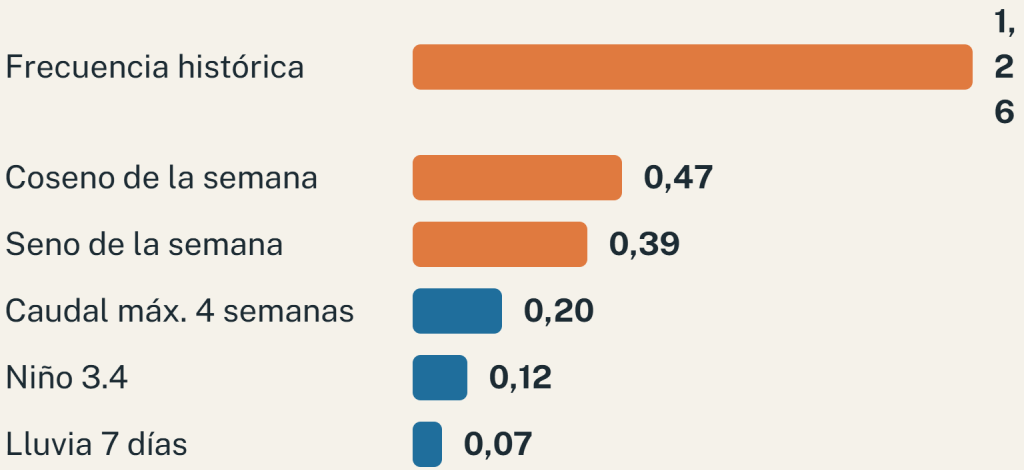
Falla en Piura: captura solo el 5 % de sus emergencias; en Tumbes, el 46 %.

Fuentes: metricas_resumen.csv · bootstrap de 2 000 remuestreos por años (ml_evaluacion.json) · 10

¿POR QUÉ TODAVÍA NO ALCANZA PARA ALERTAR?

El modelo se apoya en la historia, no en la lluvia

Cuánto pesa cada variable (SHAP medio, LightGBM)



Naranja: historia y época · azul: clima y ríos.

Riesgo medio de enero a abril (0–100)

Periodo	Riesgo	Veces
Años normales	78,2	1,0
El Niño 2017	82,6	1,1
Yaku 2023	79,8	1,0

Los ordena primero, pero apenas por encima de un año normal. Causas: lluvia en celdas de ~50 km y emergencias con fecha solo hasta 2015.

Fuentes: importancia_shap.csv y riesgo.json (revisión fuera de muestra 2016–2026) · 11

RESULTADO MÁS SÓLIDO · EXPOSICIÓN

La exposición sí ordena bien a los distritos que más se inundan

En la zona inundable de 1 en 100 años (JRC):

408 970
personas

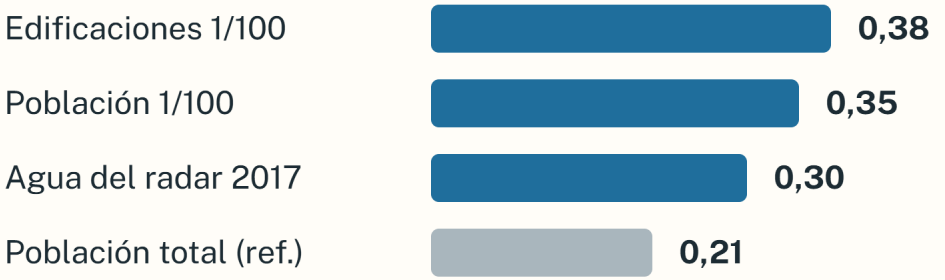
152 486
edificaciones

684
colegios

146
establecimientos de salud

Expuesto no es afectado: es un escenario con 1 % de probabilidad al año.

Correlación (ρ de Spearman) con los afectados por inundación de INDECI 2003–2024, 76 distritos:



9 de 15 distritos coinciden en el top 15. La lluvia intensa no la representa (ρ = 0,14).

INDECI SINPAD-COEN, fuente no usada en el cálculo · p < 0,01 en las tres primeras · 12

LÍMITE 1 DEL SATÉLITE · EL REZAGO

El satélite llega tarde: cuando pasa, el agua ya bajó

Día 0

Se desborda el río Piura en la ciudad (27 de marzo de 2017).

Días 1 a 4

El satélite está dando la vuelta a la Tierra. El agua drena.

Día 5

Pasa Sentinel-1: solo 0,03 km² de agua. **No detectado.**

Día 11 a 17

Siguiente pasada: revisita de 6 a 12 días.

Pasó igual en 2026: en Máncora, Tumbes y Chulucanas el radar marcó **0 km²**.

Las fotos ópticas (Sentinel-2) son peores: en temporada de lluvias las tapan las nubes.

Fuente: prueba del detector con 13 eventos (prueba_noticias.json, docs/09) · revisita: ESA Sentinel-1 · 13

LÍMITE 2 DEL SATÉLITE · LA CIUDAD

En la ciudad, el cemento confunde al radar

El radar reconoce el agua porque es lisa y se ve **oscura**.

Paredes, techos y pistas rebotan la señal y se ven **muy brillantes**. El agua entre edificios queda escondida.

Catacaos 2017, de los más inundados, solo mostró 1,1 km².

13 inundaciones de noticias: ¿las vio el radar?

Tipo de evento	Detectados
Desborde en el llano	4 de 6
Calles inundadas por lluvia	0 de 4
Desborde dentro de un poblado	0 de 2
Río angosto en la sierra	0 de 1

Lo que hicimos: bajar umbrales solo marca arena y salinas. Por eso el tablero ahora muestra toda inundación reportada, la vea o no el radar.

Fuente: docs/09_EVENTOS_REPORTADOS.md · Sentinel-1, píxel de ~55 m, detección desde 0,05 km² · 14

CONCLUSIONES

Dónde estamos y qué sigue

Lo sólido

Exposición por distrito, validada con INDECI.

El modelo ordena bien los años de El Niño.

Lo débil

No alerta semana a semana: la lluvia pesa poco.

El satélite llega tarde y no ve la ciudad ni la lluvia local.

Lo que sigue

Serie fechada de emergencias 2016–2026 (SINPAD).

Estaciones SENAMHI y capa de lluvia urbana.

Ampliar a la costa norte.